

LAPORAN 3
ANALISIS JUMLAH BAYI DENGAN BERAT BADAN LAHIR
RENDAH (BBLR) PER KECAMATAN DI KOTA BANDUNG TAHUN
2019 MENGGUNAKAN MODEL GWR (*GEOGRAPHICALLY*
***WEIGHTED REGRESSION*)**



Disusun oleh:

Kelompok C

Abiel Athaya Putra	2006532891
Alfia Choirun Nisa	1906299414
Auranissa Efrida P.	2006571192
Rahmi Radhia Khalqi	1906375796
Yasmin Khairunnisa	2006571091

PROGRAM STUDI STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS INDONESIA

2022

DAFTAR ISI

DAFTAR ISI.....	2
DAFTAR TABEL.....	4
DAFTAR GAMBAR.....	5
BAB I PENDAHULUAN.....	6
1.1. Latar Belakang	6
1.2. Rumusan Masalah	6
1.3. Tujuan.....	7
1.4. Metode Penelitian.....	7
BAB II LANDASAN TEORI.....	8
2.1. Definisi GWR.....	8
2.2. Model <i>Geographically Weighted Regression</i> (GWR)	8
2.3. Langkah Kerja Model GWR	10
2.4. Asumsi Model GWR	10
2.5. Pendugaan Parameter Model GWR	12
2.6. Matriks Fungsi Pembobot	12
BAB III ANALISIS DATA.....	14
3.1. Data	14
3.2. Analisis Data Menggunakan Regresi Linear Berganda	15
3.3. Uji Asumsi <i>Geographically Weighted Regression</i> (GWR).....	16
3.4. Analisis Data Menggunakan <i>Geographically Weighted Regression</i> (GWR)	18
3.5. Pemilihan Model Terbaik.....	23
3.6. Sebaran Variabel Signifikan.....	24
3.6.1. Keragaman Spasial Penduga Parameter β_1	25
3.6.2. Keragaman Spasial Penduga Parameter β_7	25
3.6.3. Keragaman Spasial Penduga Parameter β_8	26
3.7. Residual Model Regresi dan GWR	27
3.7.1. Residual dan <i>Studentized</i> Residual Model Regresi Linier	28
3.7.2. Residual dan <i>Studentized</i> Residual Model GWR Gaussian	29
3.7.3. Residual dan <i>Studentized</i> Residual Model GWR Bisquare	31
3.7.4. Residual dan <i>Studentized</i> Residual Model GWR Tricube	32
BAB IV PENUTUP.....	34
4.1. Kesimpulan.....	34
4.2. Saran.....	34

DAFTAR PUSTAKA	35
LAMPIRAN.....	36
Data	36
Data estimasi parameter tiap fitur (Gaussian).....	36
Output RStudio	38
Matriks Jarak antar Lokasi Pengamatan	38
Estimasi Parameter Model GWR (Kernel Gaussian).....	38
Estimasi Parameter Model GWR (Kernel Tricube).....	40
Output sebaran peubah signifikan.....	40
Input R Code	41

DAFTAR TABEL

Tabel 3.1 Variabel Terikat	14
Tabel 3.2 Variabel Bebas	14
Tabel 3.3 <i>Head and Tail</i> Data BBLR di Kota Bandung Pada Tahun 2019	14
Tabel 3.4 Perbandingan Skor AIC dan R-squared untuk Model.....	23
Tabel 3.5 Kelompok Variabel Bebas yang Signifikan Memengaruhi Variabel Terikat	24
Tabel 3.6 Nilai Max dan Min Residual	27
Tabel 3.7 Nilai Max dan Min Studentized Residual	28

DAFTAR GAMBAR

Gambar 3.1 <i>Pseudo-Stepwise</i> Kernel Gaussian	19
Gambar 3.2 Grafik Nilai CV Kernel Gaussian.....	19
Gambar 3.3 <i>Pseudo-Stepwise</i> Kernel Bisquare	20
Gambar 3.4 Grafik Nilai CV Kernel Bisquare	20
Gambar 3.5 <i>Pseudo-Stepwise</i> Kernel Tricube.....	21
Gambar 3.6 Grafik Nilai CV Kernel Tricube	21
Gambar 3.7 Peta Kelompok Kecamatan berdasarkan Variabel Bebas yang Signifikan	24
Gambar 3.8 Peta Sebaran Nilai Penduga Parameter β_1	25
Gambar 3.9 Peta Sebaran Nilai Penduga Parameter β_7	26
Gambar 3.10 Peta Sebaran Nilai Penduga Parameter β_8	27
Gambar 3.11 Peta Sebaran Nilai Residual Regresi Linear Berganda	28
Gambar 3.12 Peta Sebaran Nilai <i>Studentized</i> Residual Regresi Linear Berganda	29
Gambar 3.13 Peta Sebaran Nilai Residual	30
Gambar 3.14 Peta Sebaran Nilai <i>Studentized</i> Residual	30
Gambar 3.15 Peta Sebaran Nilai Residual	31
Gambar 3.16 Peta Sebaran Nilai <i>Studentized</i> Residual Model GWR Bisquare	31
Gambar 3.17 Peta Sebaran Nilai Residual Model GWR Tricube	32
Gambar 3.18 Peta Sebaran Nilai <i>Studentized</i> Residual Model GWR Tricube.....	33

BAB I

PENDAHULUAN

1.1. Latar Belakang

Bayi dengan Berat Badan Lahir Rendah (BBLR) didefinisikan sebagai bayi dengan berat lahir kurang dari 2.500 gram (Setyarini dan Suprapti, 2016). Berat lahir ini merupakan berat yang ditimbang satu jam setelah sang bayi lahir. Bayi yang dilahirkan dengan berat lahir kurang dari 2500 gram bukan hanya dapat terjadi pada bayi prematur, namun juga pada bayi cukup bulan yang mengalami hambatan selama kehamilan sang ibu. Sampai sekarang hal ini masih menjadi permasalahan yang sering terjadi di berbagai belahan dunia, hal ini cukup meresahkan dikarenakan dianggap menjadi salah satu faktor penyebab kematian pada bayi. Penyebab hal ini terjadi dibagi menjadi tiga faktor yaitu faktor ibu seperti usia ibu yang tidak berada di usia dengan reproduksi yang sehat dan aman, paritas yang merupakan jumlah janin dengan berat lebih dari atau sama dengan 500 gram yang pernah dilahirkan hidup maupun mati, status gizi ibu yang kurang, dan anemia. Lalu faktor janin seperti hidramnion dan kehamilan kembar atau ganda. Serta faktor lingkungan seperti sosio-ekonomi, misalnya pekerjaan, pendapatan, dan pendidikan ibu.

Pemerintah harus mengerti faktor-faktor yang mempengaruhi jumlah berat badan lahir rendah pada bayi. Kita dapat lakukan analisis regresi linier untuk menganalisis hubungan antara jumlah bayi BBLR dan faktor-faktor penyebabnya. Analisis regresi dapat kita lakukan ke data spasial yang akan memberikan pendugaan parameter yang baik apabila hubungan antara peubah bebas dan terikat bersifat stasioner yang berarti hubungan antar peubah bersifat tetap pada setiap wilayah pengambilan data. Pada data fenomena sosial seperti kasus ini, hubungan antar peubah pada data kemungkinan bersifat non stasioner yang berarti terjadi heterogen spasial. Heterogen spasial disebabkan oleh faktor-faktor perbedaan kondisi geografi, sosial & budaya, ekonomi, dan politik pada setiap wilayah. *Geographically Weighted Regression* (GWR) dilakukan pada pemodelan hubungan antara peubah bebas dan terikat karena terjadinya heterogen spasial. Kami lakukan metode *Geographically Weighted Regression* (GWR) pada data BBLR Kota Bandung tahun 2019.

1.2. Rumusan Masalah

1. Bagaimana memodelkan hubungan jumlah bayi berat badan lahir rendah (BBLR) dengan faktor-faktor yang mempengaruhinya di Kota Bandung pada tahun 2019 menggunakan metode *Geographically Weighted Regression* (GWR)?

2. Bagaimana perbandingan antara model regresi linier, model *Geographically Weighted Regression* (GWR) yang dihasilkan menggunakan fungsi Kernel Gaussian, model *Geographically Weighted Regression* (GWR) yang dihasilkan menggunakan fungsi Kernel Bisquare, dan model *Geographically Weighted Regression* (GWR) yang dihasilkan menggunakan fungsi Kernel Tricube dalam menganalisis data jumlah bayi berat badan lahir rendah (BBLR) dengan faktor-faktor yang mempengaruhinya di Kota Bandung pada tahun 2019?

1.3. Tujuan

1. Untuk menganalisis hubungan antara Jumlah Bayi dengan BBLR dengan faktor-faktor penyebabnya di Kota Bandung pada Tahun 2019 dengan Metode GWR.
2. Untuk membandingkan model regresi linear dan model GWR yang dihasilkan dengan menggunakan tiga fungsi kernel, yaitu Gaussian, Bi-Square, dan Tricube dalam menganalisis hubungan antara Jumlah Bayi dengan BBLR dan faktor-faktor penyebabnya di Kota Bandung pada Tahun 2019.

1.4. Metode Penelitian

Pada penelitian ini dilakukan analisis model jumlah bayi berat badan lahir rendah (BBLR) di Kota Bandung pada tahun 2019 dengan menggunakan analisis spasial dan *Geographically Weighted Regression* (GWR) dengan fungsi Kernel Gaussian, Kernel Bi-Square, dan Kernel Tricube sebagai fungsi pembobot.

BAB II

LANDASAN TEORI

2.1. Definisi GWR

Geographically Weighted Regression (GWR) merupakan metode yang membentuk analisis regresi namun bersifat lokal untuk setiap lokasi dan nilai parameternya berlaku hanya pada tiap lokasi pengamatan yang berbeda dengan lokasi lainnya. Terdapat matriks pembobot yang merupakan nilai untuk setiap lokasi yang besarnya bergantung pada jarak antarlokasi yang bila semakin dekat suatu lokasi, bobot pengaruhnya akan semakin besar. Fungsi pembobot yang digunakan untuk model GWR adalah fungsi kernel Gaussian, Bi-square, dan Tricube.

2.2. Model *Geographically Weighted Regression* (GWR)

Model *Geographically Weighted Regression* (GWR) adalah bentuk lokal dari regresi linier klasik yang memperhatikan aspek spasial atau lokasi geografis yang berupa koordinat titik. Model ini merupakan pengembangan dari model regresi global yang mengambil ide dasar dari regresi non parametrik. Model GWR dapat ditulis sebagai berikut:

$$y_i = \beta_0(u_i, v_i) + \sum_{k=1}^p \beta_k(u_i, v_i) x_{ik} + \varepsilon_i, \varepsilon_i \sim NIID(0, \sigma^2)$$

Dengan:

- y_i : Nilai observasi variabel respon ke-i
- x_{ik} : Nilai observasi variabel prediktor k pada pengamatan ke-I
- (u_i, v_i) : Menyatakan titik koordinat (longitude, latitude) lokasi ke-i
- $\beta_0(u_i, v_i)$: Konstanta/intercept GWR
- $\beta_k(u_i, v_i)$: Koefisien regresi ; $k = 0, 1, \dots, p$
- ε_i : Error pada titik lokasi ke-I yang diasumsikan independent, identic, dan berdistribusi normal dengan rata-rata normal dan varians σ^2 .

Parameter β dalam GWR dapat ditaksir dengan menggunakan metode kuadrat terkecil atau Weighted Least Square (WLS) sebagai berikut:

$$\hat{\beta}(u_i, v_i) = [X^T W(u_i, v_i) X]^{-1} X^T W(u_i, v_i) Y$$

Dalam proses analisis GWR, diperlukan matriks pembobot. Matriks ini merupakan nilai untuk setiap lokasi yang besarnya bergantung pada jarak antarlokasi. Semakin dekat

suatu lokasi, bobot pengaruhnya akan semakin besar. Pembobot dalam GWR dapat ditentukan dengan menggunakan fungsi Kernel sebagai berikut:

1. Fungsi Kernel Tetap (*Fixed Kernel*)

Fungsi kernel tetap memiliki *bandwidth* yang sama pada setiap titik lokasi pengamatan.

- Fungsi Kernel Gaussian

$$W_i = e \left[-\frac{1}{2} \left(\frac{d_i}{b} \right)^2 \right]$$

- Fungsi Kernel Adaptif Bi-square

$$W_i = \left\{ \left[1 - \left(\frac{d_i}{b} \right)^2 \right]^2, d_i < b \right\}$$

2. Fungsi Kernel Adaptif (*Adaptive Kernel*)

Fungsi Kernel Adaptif memiliki *bandwidth* yang berbeda untuk setiap titik lokasi pengamatan. Ini disebabkan kemampuan fungsi Kernel Adaptif yang dapat disesuaikan dengan kondisi titik-titik pengamatan.

- Fungsi Kernel Adaptif Gaussian

$$W_i = e \left[-\frac{1}{2} \left(\frac{d_i}{b_{i(q)}} \right)^2 \right]$$

- Fungsi Kernel Adaptif Bi-square

$$W_i = \left\{ \left[1 - \left(\frac{d_i}{b_{i(q)}} \right)^2 \right], d_i < b \right\}$$

Dengan $b_{i(q)}$ adalah *bandwidth* adaptif yang menetapkan q sebagai jarak tetangga terdekat dari titik lokasi pengamatan ke-i, dan d_i adalah jarak Euclidean antara titik lokasi pengamatan ke-i dengan titik lokasi pengamatan ke-j.

$$d_i = \sqrt{(u_i - u_j)^2 + (v_i - v_j)^2}$$

Bandwidth sendiri dapat dianalogikan sebagai radius (b) suatu lingkaran, sehingga sebuah titik lokasi pengamatan yang berada dalam radius lingkaran masih dianggap berpengaruh dalam membentuk parameter di titik lokasi pengamatan ke-i. Metode yang digunakan untuk menentukan *bandwidth* optimum adalah metode validasi silang atau

Cross Validation (CV) $C = \sum_{i=1}^n [y_i - \overline{y_{i \neq i}}(b)]^2$ dimana nilai bandwidth optimum diperoleh ketika CV minimum.

2.3. Langkah Kerja Model GWR

1. Membentuk model Geographically Weighted Regression (GWR) yang sesuai dari data.
2. Menggunakan fungsi pembobot Kernel Gaussioan dan Kernel Bisquare untuk menentukan pembobot.
3. Menggunakan metode Pseudo-stepwise untuk memilih peubah bebas model GWR
4. Menentukan bandwidth optimum.
5. Menentukan matriks pembobot spasial.
6. Melakukan estimasi parameter model GWR.
7. Menentukan model terbaik berdasarkan kriteria yaitu skor *Akaike's Information Criteria* (AIC) dan koefisien determinasi.
8. Melakukan uji signifikansi parameter model GWR yang terbaik.
9. Membuat peta sebaran parameter model GWR.

2.4. Asumsi Model GWR

Uji asumsi klasik merupakan uji data yang digunakan untuk mengetahui apakah data penelitian memenuhi syarat untuk dianalisis lebih lanjut, guna menjawab hipotesis penelitian. Jenis pengujian asumsi klasik juga disesuaikan dengan teknik analisis yang digunakan.

1. Normalitas

Uji distribusi normal memiliki prinsip membandingkan antara distribusi data yang didapatkan (*observed*) dan data distribusi normal (*expected*). Hal tersebut ada karena dalam statistik parametrik distribusi data yang normal adalah suatu keharusan dan merupakan syarat mutlak yang harus terpenuhi. Apabila asumsi kenormalan tidak terpenuhi, maka estimasi OLS tidak dapat digunakan. Uji normalitas memiliki fungsi untuk menguji apakah nilai residual yang terstandarisasi pada model regresi distribusi normal atau tidak. Salah satu cara mengujinya adalah dengan Uji Anderson Darling

$$A^2 = -n - S$$

Di mana

$$S = \sum_{i=1}^N \frac{(2i-1)}{N} [\log F(Y_i) + \log(1 - F(Y_{N+1-i}))]$$

Dengan keputusan menolak H_0 jika $A^2 > AD_{tabel}$ atau $p - value < \alpha$

2. Heteroskedastisitas

Heteroskedastisitas adalah asumsi yang menyatakan bahwa varian setiap sisaan tidak sama baik untuk nilai-nilai pada variabel independen yang kecil maupun besar. Asumsinya dapat ditulis sebagai berikut:

$$Var(e_i) \neq \sigma^2, i = 1, 2, \dots, n$$

n menunjukkan jumlah observasi. Salah satu cara melihat adanya heteroskedastisitas adalah dengan melihat pola sebaran sisaan terhadap nilai estimasi Y . Jika sebaran sisaan bersifat acak, maka dinyatakan bahwa variansi sisaan homogen. Salah satu cara mendeteksi heteroskedastisitas yaitu menggunakan Uji Breush-Pagan.

3. Multikolinearitas

Uji multikolinieritas adalah syarat untuk semua uji hipotesis kausalitas dan digunakan dalam analisis klaster. Kasus multikolinieritas dapat diuji dengan patokan nilai VIF dan koefisien korelasi antarvariabel bebas. Asumsi multikolinieritas lokal menggunakan kriteria $VIF_k(u_i, v_i)$ dimana multikolinieritas lokal terdeteksi jika nilai $VIF_k(u_i, v_i) > 10$. Nilai $VIF_k(u_i, v_i)$ dinyatakan sebagai berikut:

$$VIF_k(u_i, v_i) = \frac{1}{1 - R_K^2}(u_i, v_i)$$

4. Autokorelasi

Autokorelasi adalah adanya korelasi antara anggota serangkaian observasi yang diurutkan menurut waktu atau ruang. Autokorelasi memiliki konsekuensi estimasi masih linier atau tidak bias serta konsisten dan secara asimptosis terdistribusi secara normal, namun estimator-estimator tersebut tidak efisien. Jika varians tidak minimum, maka akan menyebabkan perhitungan SE tidak lagi dipercaya kebenarannya. Pengujian secara empiris dapat dilakukan menggunakan statistik Uji Durbin Watson.

$$d = \frac{\sum_{i=2}^p (e_i - e_{i-1})^2}{\sum_{i=1}^p e_i^2}$$

Uji Durbin Watson menurunkan nilai kritis bawah (dL) dan batas atas (DU) sehingga jika nilai d hitung dari persamaan di atas terletak di luar nilai kritis, maka ada atau tidaknya autokorelasi baik positif atau negatif dapat diketahui.

2.5. Pendugaan Parameter Model GWR

Pendugaan parameter model *Geographically Weighted Regression* dilakukan dengan metode *Weighted Least Squares* (WLS) yaitu dengan memberikan pembobot yang berbeda untuk setiap lokasi saat data diamati. Model GWR diasumsikan bahwa daerah yang dekat dengan lokasi pengamatan ke- i mempunyai pengaruh yang lebih besar terhadap estimasi parameternya daripada daerah yang lebih jauh.

Pendugaan parameter dilakukan dengan meminimumkan Jumlah Kuadrat Galat Terboboti (JKGT). Jumlah kuadrat galat terboboti pada model GWR di lokasi ke- i dirumuskan sebagai berikut.

$$JKGT = \sum_{i=1}^n w_i(u_i, v_i) \varepsilon_i^2$$

2.6. Matriks Fungsi Pembobot

Matriks pembobot spasial adalah matriks diagonal berukuran $(n \times n)$ dengan elemen diagonal $w_j(u_i, v_i)$. Nilai pembobot spasial $w_1(u_i, v_i), w_2(u_i, v_i), \dots, w_n(u_i, v_i)$ didapat dari fungsi pembobot spasial dengan nilai bobot antara 0 sampai 1 berdasarkan jarak antar titik dibangunnya model dengan titik observasi. Nilai bobot maksimal adalah 1 yang didapat jika titik dibangunnya model sama dengan titik observasi. Semakin jauh titik observasi dengan titik dibangunnya model, maka nilai bobot akan semakin kecil. Jarak Euclidian titik observasi ke- i dan ke- j dapat dinyatakan sebagai rumus berikut:

$$d_{ij} = \sqrt{(u_i - u_j)^2 + (v_i - v_j)^2}$$

Maka bobot titik observasi ke- j untuk model pada lokasi ke- i adalah:

$$w_j(u_i, v_i) = K(d_{ij})$$

Dengan $K(d_{ij})$ adalah fungsi pembobot spasial.

Fungsi pembobot spasial yang baik akan memenuhi sifat-sifat sebagai berikut:

1. $K(0) = 1$
2. $\lim_{d_{ij} \rightarrow \infty} K(d_{ij}) = 0$
3. $K(d_{ij})$ adalah fungsi yang monoton turun.

Jenis-jenis dari fungsi pembobot spasial, yaitu:

1. Fungsi Kernel Gaussian

$$K_G(d_{ij}) = \exp \left[-\frac{1}{2} \left(\frac{d_{ij}}{b} \right)^2 \right]$$

Di mana

d_{ij} : jarak antara lokasi dibangunnya model GWR (i) dan lokasi observasi lainnya (j).

b : nilai *bandwidth* optimum.

2. Fungsi Kernel Bisquare

$$K_B(d_{ij}) = \left[1 - \frac{1}{2} \left(\frac{d_{ij}}{b} \right)^2 \right]^2$$

Di mana

d_{ij} : jarak antara lokasi dibangunnya model GWR (i) dan lokasi observasi lainnya (j).

b : nilai *bandwidth* optimum.

BAB III

ANALISIS DATA

3.1. Data

Data yang digunakan dalam penelitian ini adalah data sekunder yang dihimpun oleh Badan Pusat Statistik Kota Bandung. Variabel terikat yang digunakan dalam penelitian ini adalah jumlah Berat Badan Bayi Lahir Rendah (BBLR) di Kota Bandung pada tahun 2019.

Tabel 3.1 Variabel Terikat

Variabel Terikat	Simbol
Jumlah Berat Badan Bayi Lahir Rendah pada tahun 2019 (per kecamatan)	BBLR

Variabel bebas yang digunakan dalam penelitian ini adalah faktor-faktor penentu jumlah penduduk miskin di Provinsi Jawa Tengah pada tahun 2019, yaitu sebagai berikut.

Tabel 3.2 Variabel Bebas

Variabel Bebas	Simbol
Pemberian FE1 (Zat Besi) 30 Tablet	FE1
Pemberian FE2 (Zat Besi) 90 Tablet	FE2
Jumlah Kunjungan k1 Ibu Hamil ke Puskesmas di Kota Bandung	K1
Jumlah Kunjungan k4 Ibu Hamil ke Puskesmas di Kota Bandung	K4
Jumlah Rumah Tangga Ber-PHBS (Perilaku Hidup Bersih dan Sehat)	PHBS
Jumlah Kemiskinan	kms
Jumlah Rumah Memenuhi Syarat Tidak Sehat di Kota Bandung	RTS
Jumlah Populasi	pop
Jumlah Kepadatan Penduduk (Jiwa/Ha)	kpd

Berikut adalah *head and tail* data yang akan digunakan dalam penelitian ini.

Tabel 3.3 *Head and Tail* Data BBLR di Kota Bandung Pada Tahun 2019

No	Kecamatan	BBLR	FE1	FE2	K1	K4	PHBS	kms	RTS	pop	kpd
1	Gedebage	3	676	639	675	595	6117	394	1815	40121	40
2	Ujungberung	33	1430	1416	1505	1453	13685	1306	5087	86225	138
3	Cinambo	34	436	427	465	455	2310	323	1499	25101	59
4	Bandung Kulon	94	2347	2205	2486	2388	4857	2758	5744	132811	191
5	Andir	163	1832	1759	1729	1679	9906	1126	3357	99132	235
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
29	Rancasari	22	1407	1270	1389	1253	2831	751	0	83428	119

30	Arcamanik	91	1306	1277	1355	1271	1123	849	912	76239	100
----	-----------	----	------	------	------	------	------	-----	-----	-------	-----

3.2. Analisis Data Menggunakan Regresi Linear Berganda

Akan dilakukan analisis awal pada data Jumlah BBLR berdasarkan Kecamatan di Kota Bandung pada tahun 2019 menggunakan permodelan regresi linear. Pendugaan parameter model regresi dilakukan dengan metode *Ordinary Least Square* (OLS).

Model regresi yang terbentuk untuk *full model* dengan menggunakan bantuan RStudio, sebagai berikut.

```
Call:
lm(formula = BBLR ~ FE1 + FE2 + K1 + K4 + PBHS + kms + RTS +
    pop + kpd, data = datagwr)

Residuals:
    Min       1Q   Median       3Q      Max
-38.979 -10.619   0.115   5.127  72.829

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -3.506936   18.492312  -0.190   0.8515
FE1           0.538236    0.196545   2.738   0.0127 *
FE2          -0.266744    0.164218  -1.624   0.1200
K1           -0.245137    0.141481  -1.733   0.0986 .
K4            0.278764    0.146854   1.898   0.0722 .
PBHS          0.001649    0.001529   1.079   0.2935
kms           0.013714    0.014918   0.919   0.3689
RTS          -0.003407    0.002266  -1.504   0.1483
pop          -0.004932    0.002586  -1.907   0.0709 .
kpd           0.028689    0.108158   0.265   0.7935
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 29.42 on 20 degrees of freedom
Multiple R-squared:  0.4787,    Adjusted R-squared:  0.2442
F-statistic: 2.041 on 9 and 20 DF,  p-value: 0.08828
```

Dari *output* regresi pada *full model* di atas, dapat dilihat bahwa $p - value = 0.08828 > \alpha = 0, 05$. Sehingga H_0 tidak ditolak dan dapat disimpulkan bahwa model tersebut tidak dapat dikatakan sebagai model regresi terbaik untuk mereprediksi hubungan antara variabel bebas dan variabel terikat.

Selection Summary						
Step	Variable Entered	R-Square	Adj. R-Square	C(p)	AIC	RMSE
1	FE1	0.1831	0.1540	5.3424	295.3507	31.1268
2	pop	0.2827	0.2295	3.5228	293.4519	29.7038
3	RTS	0.3435	0.2678	3.1876	292.7920	28.9570

Kemudian dilakukan seleksi parameter dengan metode Stepwise Forward Selection dan didapat variabel yang akan digunakan yaitu variabel bebas FE1, RTS, dan pop.

```

Call:
lm(formula = y ~ FE1 + pop + RTS, data = datagwr)

Residuals:
    Min       1Q   Median       3Q      Max
-44.537 -15.248  -3.173  11.019  88.600

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -6.694283   15.329743  -0.437   0.6659
FE1           0.260733    0.118186   2.206   0.0364 *
pop          -0.003896    0.002071  -1.882   0.0711 .
RTS          -0.003070    0.001977  -1.553   0.1326
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 28.96 on 26 degrees of freedom
Multiple R-squared:  0.3435,    Adjusted R-squared:  0.2678
F-statistic: 4.535 on 3 and 26 DF,  p-value: 0.01098

```

Hasil pengujian serentak terhadap model regresi menghasilkan $p\text{-value} = 0,01098 < \alpha = 0,05$, sehingga H_0 ditolak. Hal tersebut menunjukkan bahwa paling sedikit ada satu peubah bebas yang memberikan pengaruh signifikan terhadap peubah terikat.

Nilai koefisien determinasi (R^2) yang diperoleh adalah sebesar 26,78% yang artinya keragaman jumlah kasus bayi berat badan lahir rendah (BBLR) berdasarkan kecamatan di Kota Bandung pada tahun 2019 mampu dijelaskan sebesar 26,78% oleh variabel bebas pada model, sedangkan 73,22% sisanya dijelaskan oleh variabel lain di luar model.

Berdasarkan ringkasan model tersebut, didapatkan model regresi linear berganda terbaik, yaitu:

$$\widehat{BBLR} = -6,694283 + 0,260733 (FE1) - 0,003070 (RTS) - 0,003896 (pop)$$

3.3. Uji Asumsi *Geographically Weighted Regression* (GWR)

a. Multiokolinearitas

```

> vif(model)
              FE1              pop              RTS
143.330906 143.924730  1.623887

```

Dengan syarat $vif < 10$, maka dapat dikatakan bahwa tidak terjadi multikolinearitas pada variabel bebas RTS atau Jumlah Rumah Memenuhi Syarat Tidak Sehat di Kota Bandung, dan terjadi multikolinearitas pada variabel bebas FE1 atau Pemberian FE1 (Zat Besi) 30 Tablet dan pop atau Jumlah Populasi.

b. Normalitas

Akan dilakukan uji asumsi normalitas dengan menggunakan uji Anderson-Darling.

- Hipotesis

H_0 : Error berdistribusi normal

H_1 : Error tidak berdistribusi normal

- Taraf Signifikansi

$\alpha = 0,05$

- Statistik Uji

```
Anderson-Darling normality test  
  
data: model$residuals  
A = 0.60018, p-value = 0.1086
```

- Aturan Keputusan

H_0 ditolak jika $p\text{-value} < \alpha$

- Keputusan

Nilai $p\text{-value} = 0,1086 > \alpha = 0,05$, sehingga H_0 tidak ditolak.

- Kesimpulan

Dengan taraf signifikansi sebesar 0,05 dapat disimpulkan bahwa *error* berdistribusi normal.

c. Autokorelasi

Akan dilakukan uji asumsi autokorelasi dengan menggunakan uji Durbin-Watson.

- Hipotesis

H_0 : Tidak terdapat autokorelasi

H_1 : Terdapat autokorelasi

- Taraf Signifikansi

$\alpha = 0,05$

- Statistik Uji

```
> durbinWatsonTest(model)  
lag Autocorrelation D-W Statistic p-value  
1 -0.1698384 1.964018 0.958  
Alternative hypothesis: rho != 0
```

- Aturan Keputusan

Tolak H_0 jika $p\text{-value} < \alpha = 0,05$

- Keputusan
Nilai $p\text{-value} = 0,8 > \alpha = 0,05$, sehingga H_0 tidak ditolak.
- Kesimpulan
Dengan taraf signifikansi sebesar 0,05 dapat disimpulkan bahwa tidak terdapat autokorelasi

d. Heteroskedastisitas

Akan dilakukan uji asumsi heteroskedastisitas dengan menggunakan uji Breusch-Pagan untuk mengetahui apakah varians atau keragaman dari error terpengaruh oleh faktor lain atau tidak pada model.

- Hipotesis
 H_0 : Tidak terjadi heteroskedastisitas (tidak terdapat heterogenitas spasial)
 H_1 : Terjadi heteroskedastisitas (terdapat heterogenitas spasial)
- Taraf Signifikansi
 $\alpha = 0,05$
- Statistik Uji


studentized Breusch-Pagan test

```
data: model
BP = 10.24, df = 3, p-value = 0.01664
```

- Aturan Keputusan
Tolak H_0 jika $p\text{-value} < \alpha = 0,05$.
- Keputusan
Nilai $p\text{-value} = 0,01664 < 0,05 = \alpha$, sehingga H_0 ditolak.
- Kesimpulan
Dengan taraf signifikansi sebesar 0,05 dapat disimpulkan bahwa terjadi heteroskedastisitas atau terdapat heterogenitas spasial pada data.

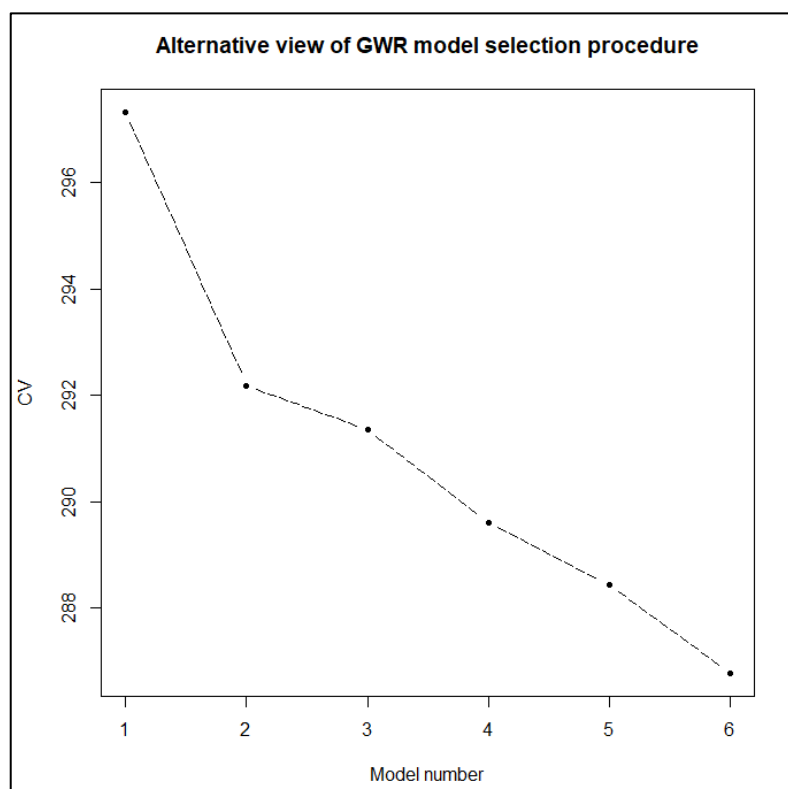
3.4. Analisis Data Menggunakan *Geographically Weighted Regression* (GWR)

Pertama, akan digunakan metode *pseudo-stepwise* untuk memilih peubah bebas yang akan digunakan dalam model GWR. Berikut adalah hasil langkah *pseudo-stepwise* yang dihasilkan menggunakan fungsi kernel Gaussian dengan bantuan RStudio.




Gambar 3.1 *Pseudo-Stepwise* Kernel Gaussian

Berikut grafik *Cross Validation* (CV) untuk Kernel Gaussian.




Gambar 3.2 Grafik Nilai CV Kernel Gaussian


Kemudian, akan digunakan juga fungsi Kernel Bisquare dan Kernel Tricube dan berikut hasil langkah *pseudo-stepwise* beserta grafik CV yang dihasilkan.




Gambar 3.3 *Pseudo-Stepwise Kernel Bisquare*



Gambar 3.4 Grafik Nilai CV Kernel Bisquare



Gambar 3.5 *Pseudo-Stepwise* Kernel Tricube



Gambar 3.6 Grafik Nilai CV Kernel Tricube

Dari ketiga grafik CV yang dihasilkan, dapat dilihat bahwa proses metode *pseudo-stepwise* berjalan dalam 6 langkah dari pelibatan satu peubah hingga tiga peubah dalam

model. Nilai CV mengalami penurunan sampai langkah ke-6, kemudian diputuskan seluruh peubah bebas, yaitu FE1, RTS, dan pop akan dilibatkan dalam penentuan berat model GWR. Keputusan ini berlaku untuk Kernel Gaussian, Kernel Bisquare, dan juga Kernel Tricube karena menghasilkan hasil yang sama.

Selanjutnya, akan ditentukan nilai *bandwidth* optimum yang akan digunakan sebagai parameter fungsi pembobot. Dengan bantuan RStudio, didapat hasil berikut.

- Kernel Gaussian

```
> bw.mod.gwr.gauss <- bw.gwr(BBLR~FE1+RTS+pop, data = data.spdf,
approach="CV", kernel="gaussian", adaptive=F)
> bw.mod.gwr.gauss
[1] 0.05530211
```

Didapat nilai *bandwidth* optimum untuk Kernel Gaussian adalah 0.05530211. Sehingga fungsi Kernel Gaussian yang didapat dari model adalah

$$K_G(d_{ij}) = \exp \left[-\frac{1}{2} \left(\frac{d_{ij}}{0.05530211} \right)^2 \right]$$

Nilai *bandwidth* optimum sebesar 0.05530211 (satuan jarak dalam sistem koordinat geografi) mengartikan bahwa kabupaten/kota yang berjarak tidak lebih 0.05530211 dari kabupaten/kota yang diamati, akan mendapatkan bobot yang (secara signifikan) lebih besar daripada kabupaten/kota yang berjarak lebih dari 0.05530211. Hal ini menyebabkan kabupaten/kota yang berjarak tidak lebih dari 0.05530211 memiliki pengaruh yang lebih besar dalam pendugaan parameter model GWR.

- Kernel Bisquare

```
> bw.mod.gwr.bisq <- bw.gwr(BBLR~FE1+RTS+pop, data = data.spdf,
approach="CV", kernel="bisquare", adaptive=F)
> bw.mod.gwr.bisq
[1] 0.1524757
```

Didapat nilai *bandwidth* optimum untuk Kernel Bisquare adalah 0.1524757. Sehingga fungsi Kernel Bisquare yang didapat dari model adalah

$$K_B(d_{ij}) = \exp \left[-\frac{1}{2} \left(\frac{d_{ij}}{0.1524757} \right)^2 \right]^2$$

Nilai *bandwidth* optimum sebesar 0.1524757 (satuan jarak dalam sistem koordinat geografi) mengartikan bahwa kabupaten/kota yang berjarak tidak lebih 0.1524757 dari kabupaten/kota yang diamati, akan mendapatkan bobot yang (secara

signifikan) lebih besar daripada kabupaten/kota yang berjarak lebih dari 0.1524757. Hal ini menyebabkan kabupaten/kota yang berjarak tidak lebih dari 0.1524757 memiliki pengaruh yang lebih besar dalam pendugaan parameter model GWR.

- Kernel Tricube

```
> bw.mod.gwr.tric <- bw.gwr(BBLR~FE1+RTS+pop, data = data.spdf,
approach="CV", kernel="tricube", adaptive=F)
> bw.mod.gwr.tric
[1] 0.1587755
```

Didapat nilai *bandwidth* optimum untuk Kernel Tricube adalah 0.1587755. Sehingga fungsi Kernel Tricube yang didapat dari model adalah

$$K_T(d_{ij}) = \exp \left[-\frac{1}{2} \left(\frac{d_{ij}}{0.1587755} \right)^3 \right]^3$$

Nilai *bandwidth* optimum sebesar 0.1587755 (satuan jarak dalam sistem koordinat geografi) mengartikan bahwa kabupaten/kota yang berjarak tidak lebih 0.1587755 dari kabupaten/kota yang diamati, akan mendapatkan bobot yang (secara signifikan) lebih besar daripada kabupaten/kota yang berjarak lebih dari 0.1587755. Hal ini menyebabkan kabupaten/kota yang berjarak tidak lebih dari 0.1587755 memiliki pengaruh yang lebih besar dalam pendugaan parameter model GWR.

3.5. Pemilihan Model Terbaik

Dari perhitungan, didapat beberapa model sebagai berikut.

Tabel 3.4 Perbandingan Skor AIC dan R-squared untuk Model


Model	AIC	R^2
Regresi Global	292,792	0,3435
GWR (Gaussian)	282,9896	0,4722886
GWR (Bisquare)	284,1475	0,4334845
GWR (Tricube)	284,7379	0,4093352

Dapat dilihat bahwa model GWR Gaussian memperoleh nilai AIC paling rendah dan nilai R^2 paling tinggi ketika dibandingkan dengan model lainnya. Dengan demikian, dapat disimpulkan bahwa model GWR Gaussian adalah model terbaik untuk menganalisis data jumlah bayi dengan Berat Badan Lahir Rendah (BBLR) di Kota Bandung pada tahun 2019.

3.6. Sebaran Variabel Signifikan

Metode GWR memberikan nilai parameter yang berbeda di setiap lokasi pengamatan. Hal ini disebabkan oleh adanya heterogenitas spasial yang mengakibatkan hubungan variabel terikat dan variabel bebas bervariasi, yang artinya tidak semua variabel bebas yang dianalisis memiliki pengaruh signifikan pada suatu lokasi.

Gambar 3.7 menunjukkan sebaran variabel bebas yang berpengaruh signifikan terhadap variabel terikat dengan tingkat signifikansi 5%. Terdapat empat kelompok lokasi berdasarkan variabel bebas yang signifikan sebagaimana dijelaskan pada Tabel 3.5.



Gambar 3.7 Peta Kelompok Kecamatan berdasarkan Variabel Bebas yang Signifikan

Dengan tingkat signifikansi 0,05, terdapat 3 kelompok lokasi berdasarkan variabel bebas yang signifikan.

Tabel 3.5 Kelompok Variabel Bebas yang Signifikan Memengaruhi Variabel Terikat

Kelompok	Peubah Signifikan	Jumlah Kecamatan	Kecamatan
0 (putih)	Tidak ada	21	Gedebage, Ujungberung, Cinambo, Cidadap, Coblong, Bandunf Wetan, Sumur Bandung, Batununggal, Cibeunying Kidul, Regol, Bandung Kidul, Kiaracondong, Buahbatu, Mandalajati, Cibiru, Cibeunying Kaler, Panyileukan, Antapani, Lengkong, Rancasari, Arcamanik
1 (biru muda)	FE1	8	Andir, Babakan Ciparay, Bojongloa Kaler, Sukajadi, Cicendo, Astanaanyar, Bojongloa Kidul, Sukasari
2 (biru tua)	FE1, pop	1	Bandung Kulon

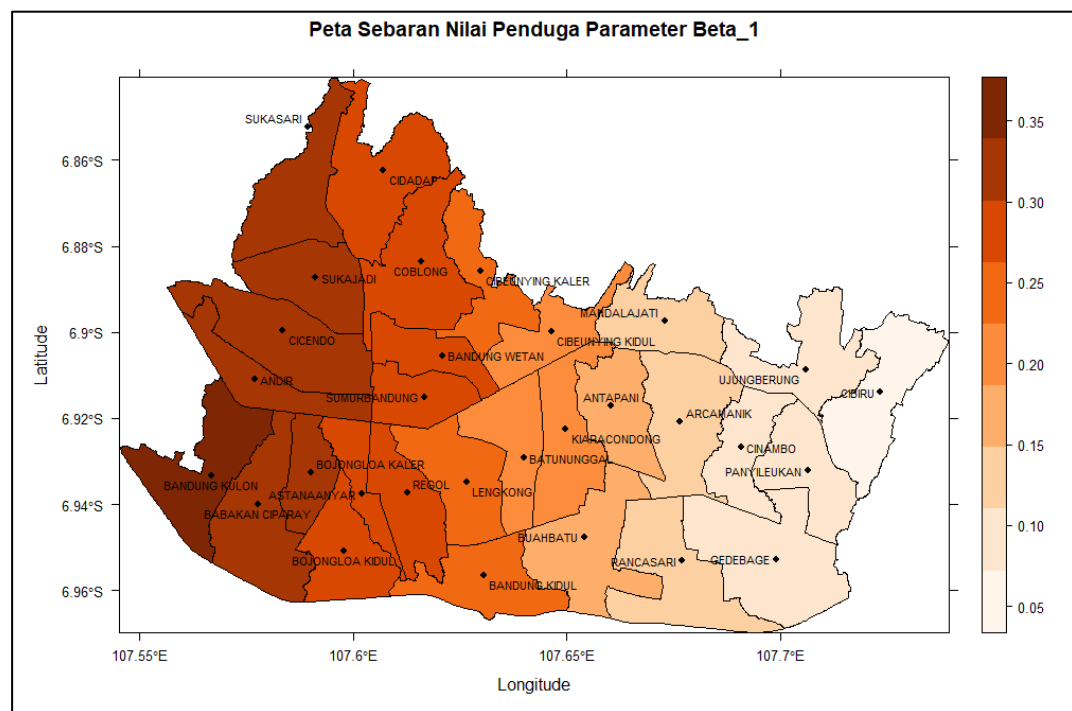
Di mana:

FE1 : Pemberian FE1 (Zat Besi) 30 tablet pada ibu hamil

pop : Jumlah populasi penduduk per kecamatan di Kota Bandung

3.6.1. Keragaman Spasial Penduga Parameter β_1

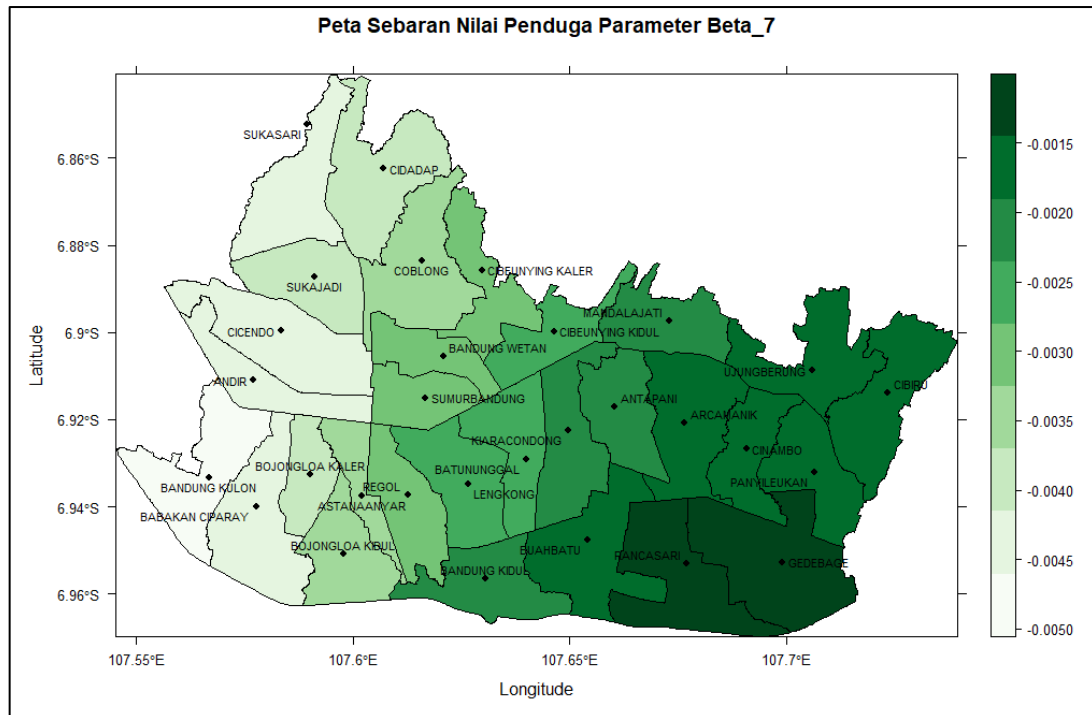
Gambar 3.8 menunjukkan sebaran nilai penduga parameter β_1 yang menggambarkan pengaruh jumlah ibu hamil yang mendapat tablet FE1 terhadap jumlah bayi berat badan lahir rendah (BBLR) per kecamatan di Kota Bandung pada tahun 2019. Gambar ini memperlihatkan bahwa nilai penduga parameter hampir sama di kecamatan yang berdekatan. Daerah yang berwarna lebih gelap memiliki nilai penduga parameter yang lebih besar.



Gambar 3.8 Peta Sebaran Nilai Penduga Parameter β_1

3.6.2. Keragaman Spasial Penduga Parameter β_7

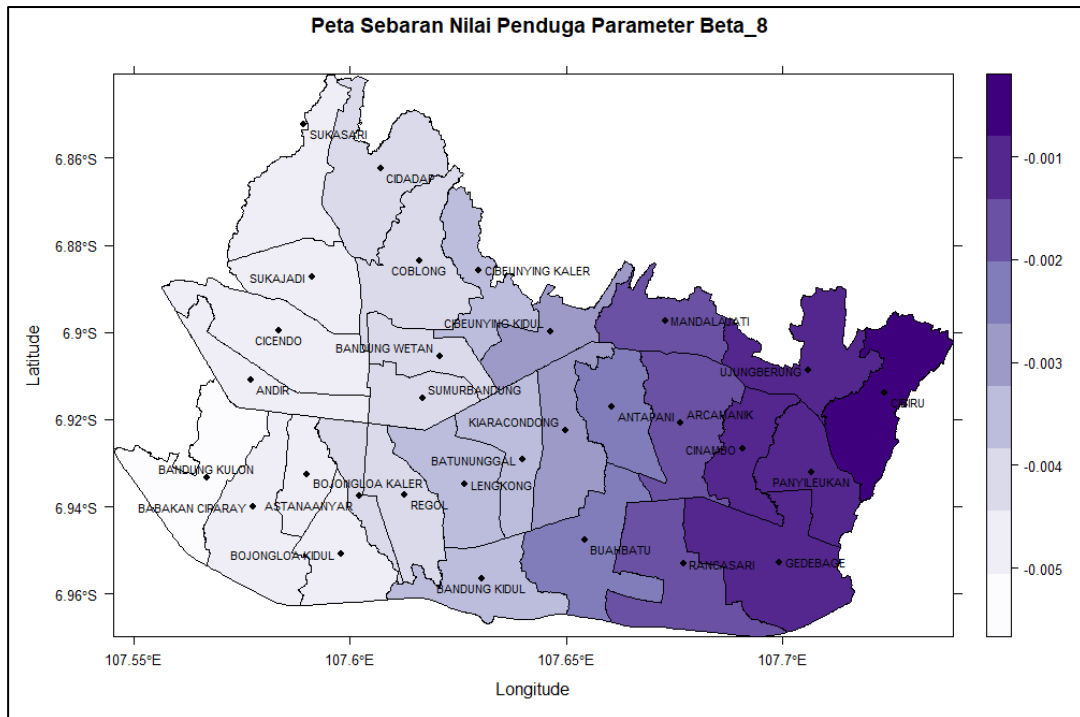
Gambar 3.9 menunjukkan sebaran nilai penduga parameter β_7 yang menggambarkan pengaruh jumlah rumah memenuhi syarat tidak sehat di Kota Bandung (RTS) terhadap jumlah bayi berat badan lahir rendah (BBLR) per kecamatan di Kota Bandung pada tahun 2019. Gambar ini memperlihatkan bahwa nilai penduga parameter hampir sama di kecamatan yang berdekatan. Daerah yang berwarna lebih gelap memiliki nilai penduga parameter yang lebih besar.



Gambar 3.9 Peta Sebaran Nilai Penduga Parameter β_7

3.6.3. Keragaman Spasial Penduga Parameter β_8

Gambar 3.10 menunjukkan sebaran nilai penduga parameter β_8 yang menggambarkan pengaruh jumlah populasi penduduk (pop) terhadap jumlah bayi berat badan lahir rendah (BBLR) per kecamatan di Kota Bandung pada tahun 2019. Gambar di bawah ini memperlihatkan bahwa nilai penduga parameter hampir sama di kecamatan yang berdekatan. Gambar ini memperlihatkan bahwa nilai penduga parameter hampir sama di kecamatan yang berdekatan. Daerah yang berwarna lebih gelap memiliki nilai penduga parameter yang lebih besar.



Gambar 3.10 Peta Sebaran Nilai Penduga Parameter β_8

3.7. Residual Model Regresi dan GWR

Residual pada regresi linier dapat dituliskan sebagai berikut.

$$e_i = Y_i - \beta X_i, \quad e_i \sim NIID(0, \sigma^2)$$

Residual akan bernilai sama dengan nol ketika nilai pengamatan terletak dalam garis regresi. Apabila total jarak atau nilai mutlak dari residual bernilai sama dengan nol, maka semua nilai pengamatan terletak pada garis regresi. Semakin besar total jarak, maka garis regresi akan semakin jauh dari nilai sebenarnya dan nilai residualnya akan semakin besar sehingga garis regresi kurang tepat digunakan untuk memprediksi baik secara interpolasi maupun ekstrapolasi. Yang diharapkan adalah total residual semakin kecil sehingga garis regresi cukup handal untuk digunakan. Sedangkan *studentized* residual merupakan nilai residual yang distandarisasi berdasarkan nilai *mean* dan *standard deviation* dari pengamatan.

Berikut adalah tabel mengenai nilai maksimum dan minimum pada residual dan *studentized* residual.

Tabel 3.6 Nilai Max dan Min Residual

Model	Min	Maks
Regresi Linear Berganda	-44,53711	88,60004
GWR Gaussian	-42,06364	76,96306
GWR Bisquare	-40,81529	79,6327

GWR Tricube	-41,18086	82,37827
-------------	-----------	----------

Tabel 3.7 Nilai Max dan Min Studentized Residual

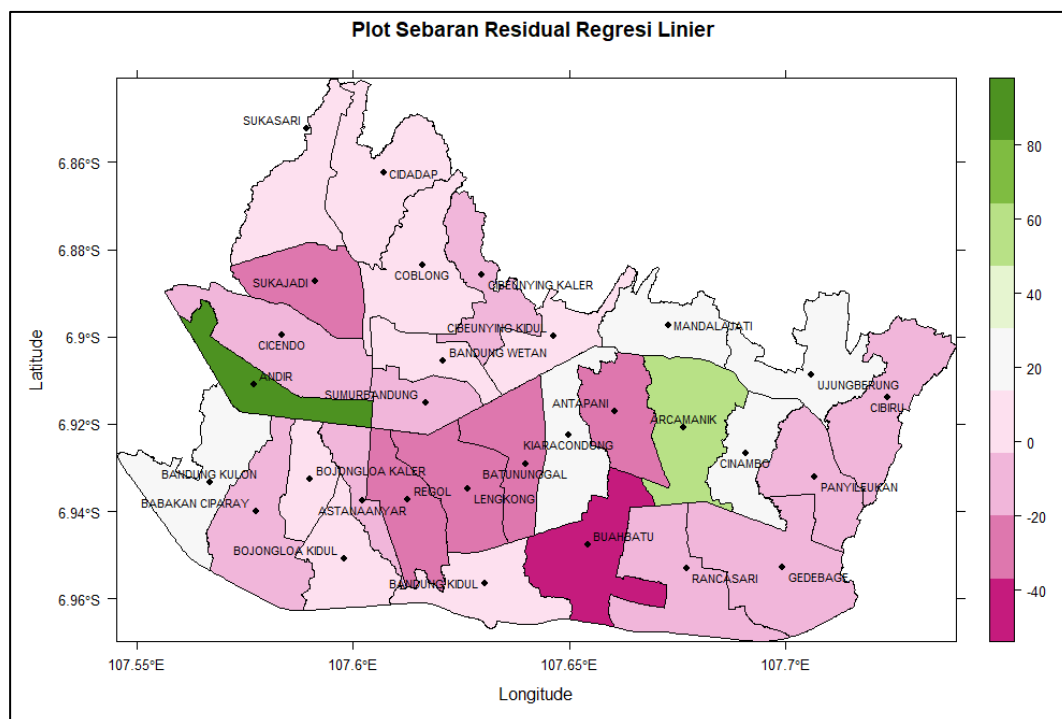
Model	Min	Max
Regresi Linear Berganda	-1,669661	4,954251
GWR Gaussian	-1,667857	3,348625
GWR Bisquare	-1,593137	3,417453
GWR Tricube	-1,53036	3,470075

Pada Tabel 3.6 dan Tabel 3.7 terlihat bahwa range nilai residual maupun *studentized* residual yang terbesar terdapat pada model regresi linear berganda dan yang terkecil adalah pada model GWR Gaussian. Dengan demikian patutlah bahwa model GWR Gaussian adalah model terbaik untuk menganalisis data jumlah bayi dengan Berat Badan Lahir Rendah (BBLR) di Kota Bandung pada tahun 2019.

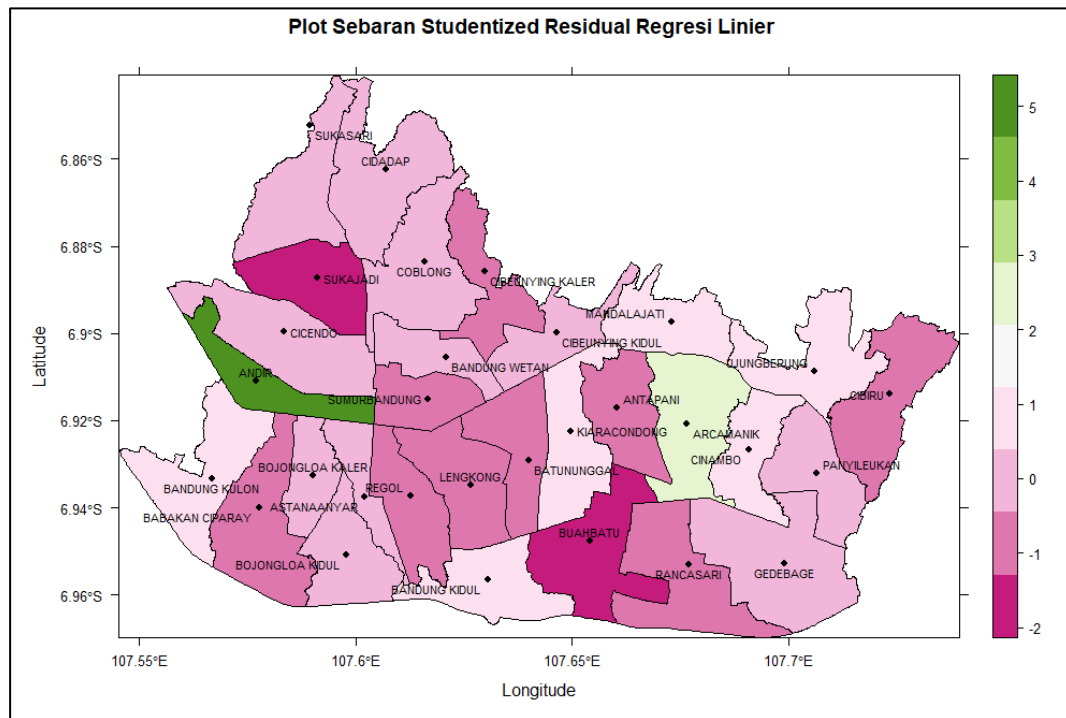
Selanjutnya akan diplot peta residual maupun *studentized* residual dari masing-masing model dengan bantuan *software* RStudio.

3.7.1. Residual dan *Studentized* Residual Model Regresi Linier

Akan dipetakan sebaran residual dan *studentized* residual model regresi linear berganda dengan bantuan *software* RStudio.



Gambar 3.11 Peta Sebaran Nilai Residual Regresi Linear Berganda

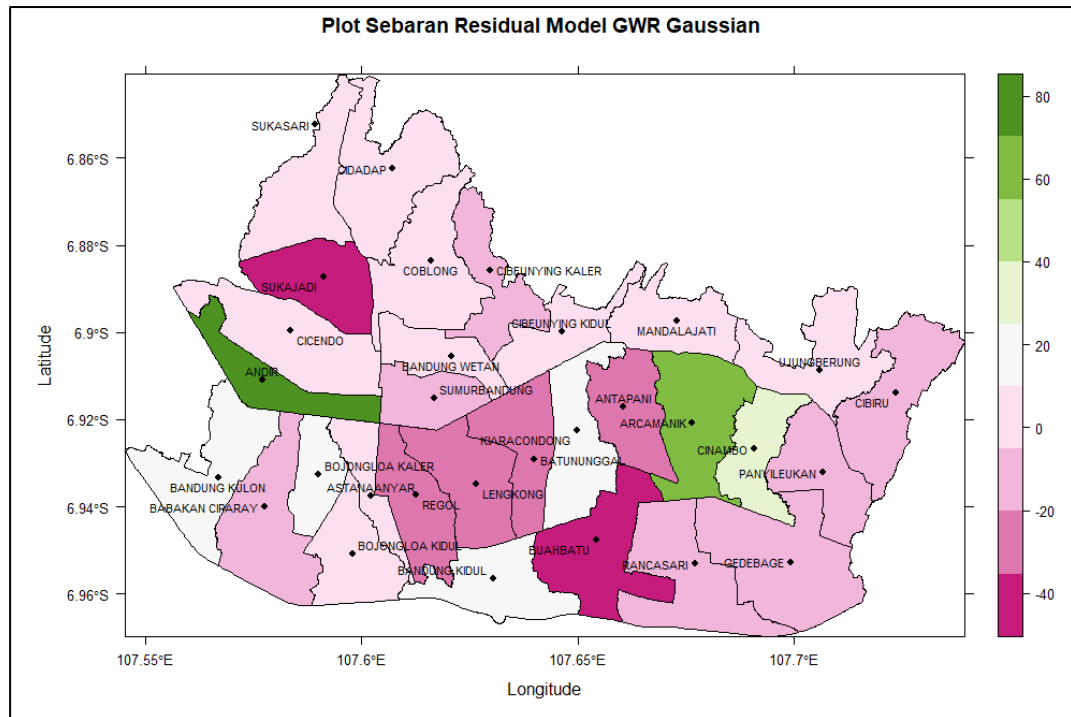


Gambar 3.12 Peta Sebaran Nilai *Studentized* Residual Regresi Linear Berganda

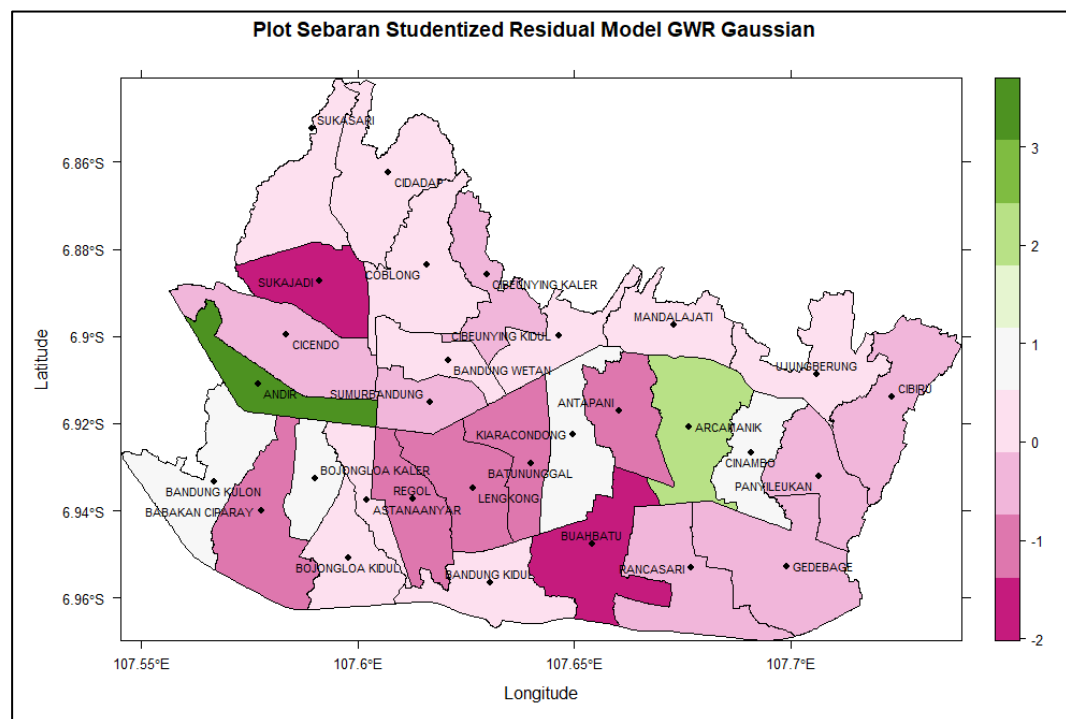
Pada peta di atas terlihat bahwa kecamatan di Kota Bandung dengan nilai mutlak dari *studentized* residual model Regresi Linear Berganda terbesar adalah Andir, Arcamanik, Buahbatu, dan Sukajadi di mana range nilai mutlaknya antara lebih dari 1,3 sampai lebih dari 4,9 sehingga daerah-daerah tersebut dapat dikatakan terdeteksi sebagai *outlier*.

3.7.2. Residual dan *Studentized* Residual Model GWR Gaussian

Akan dipetakan sebaran residual dan *studentized* residual model GWR Gaussian dengan bantuan *software* RStudio.



Gambar 3.13 Peta Sebaran Nilai Residual

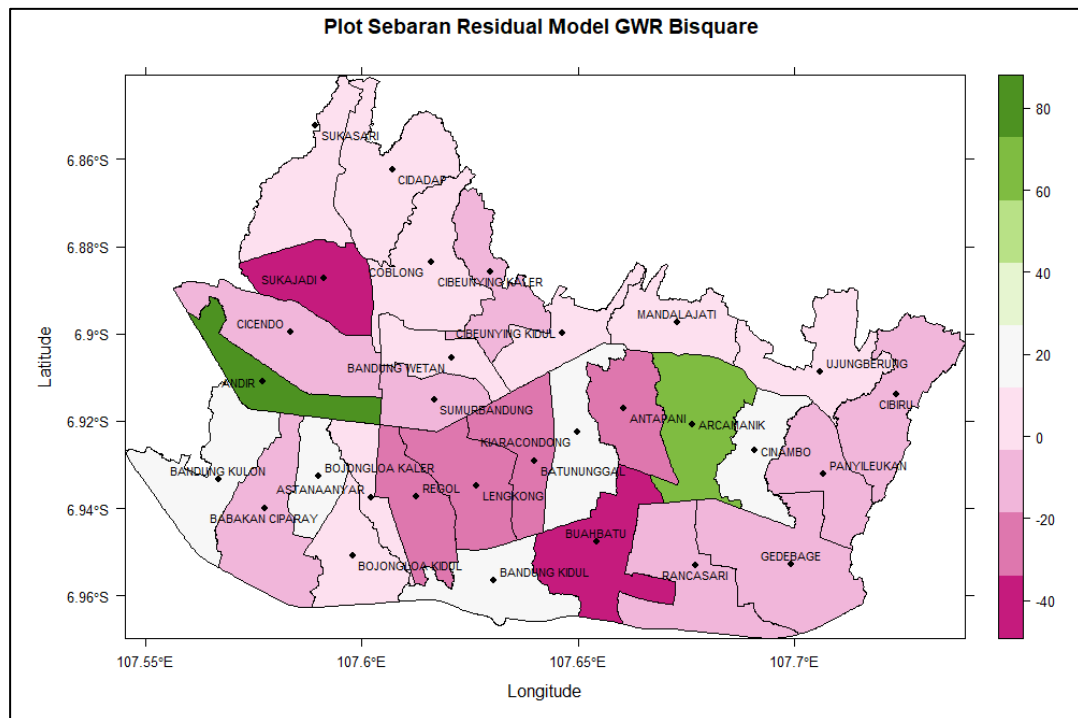


Gambar 3.14 Peta Sebaran Nilai *Studentized* Residual

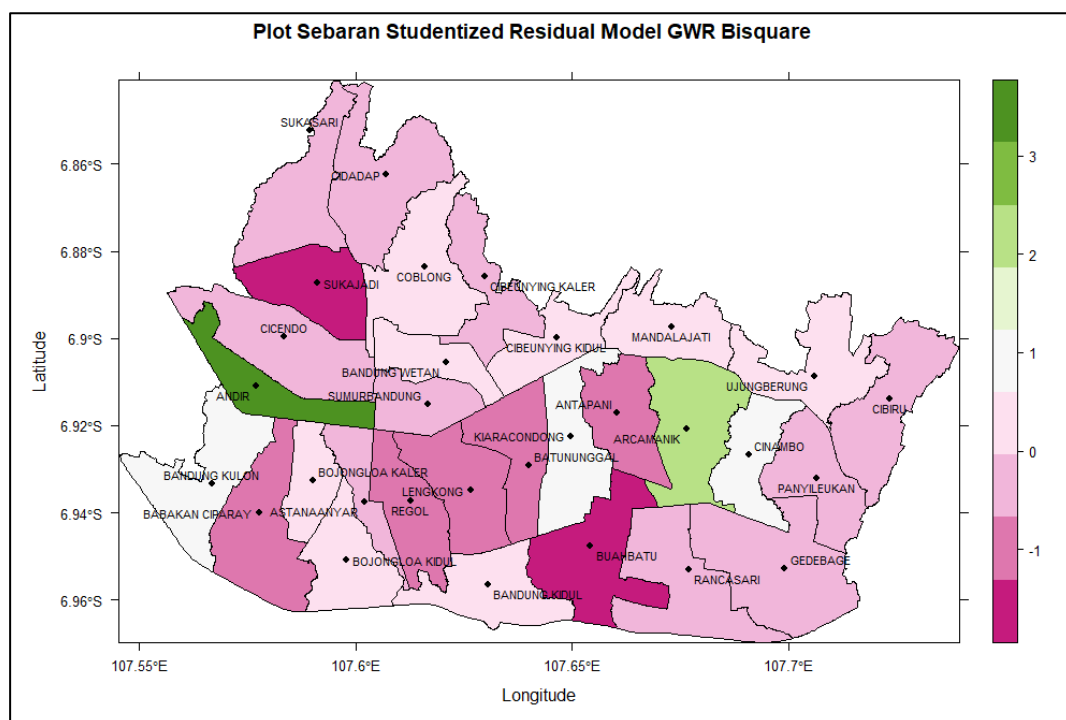
Pada peta di atas terlihat bahwa kecamatan di Kota Bandung dengan nilai mutlak dari *studentized* residual model GWR Gaussian terbesar adalah Andir, Arcamanik, Buahbatu, dan Sukajadi di mana range nilai mutlaknya antara lebih dari 1,46 sampai lebih dari 3 sehingga daerah-daerah tersebut dapat dikatakan terdeteksi sebagai *outlier*.

3.7.3. Residual dan *Studentized* Residual Model GWR Bisquare

Akan dipetakan sebaran residual dan *studentized* residual model GWR Bisquare dengan bantuan *software* RStudio.



Gambar 3.15 Peta Sebaran Nilai Residual

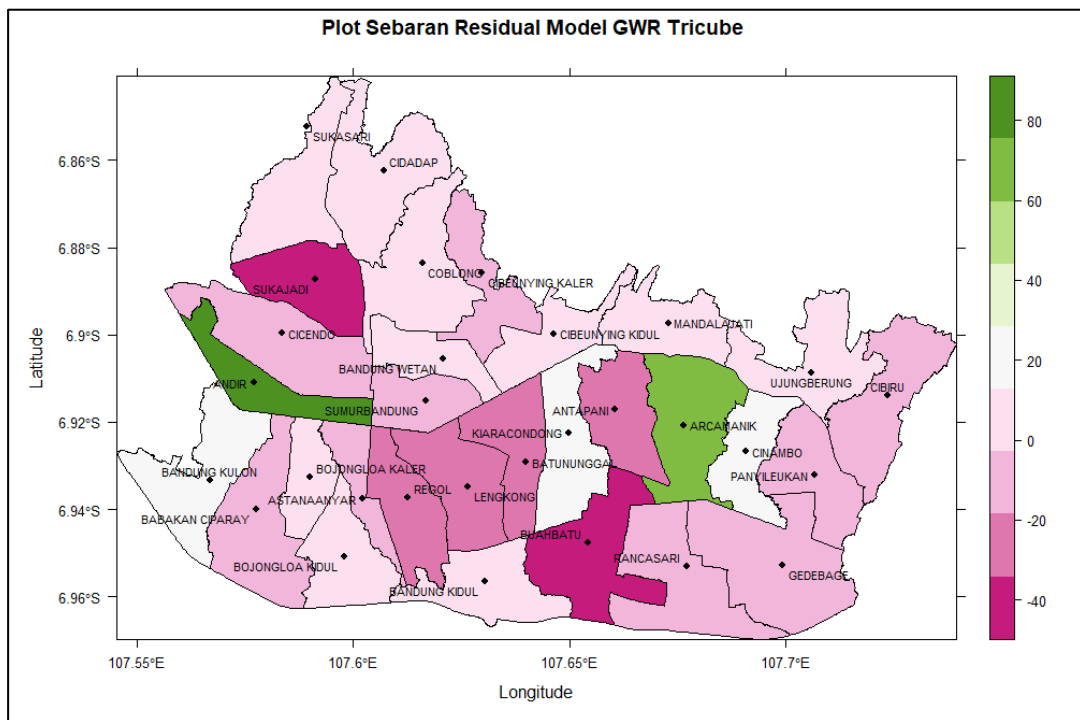


Gambar 3.16 Peta Sebaran Nilai *Studentized* Residual Model GWR Bisquare

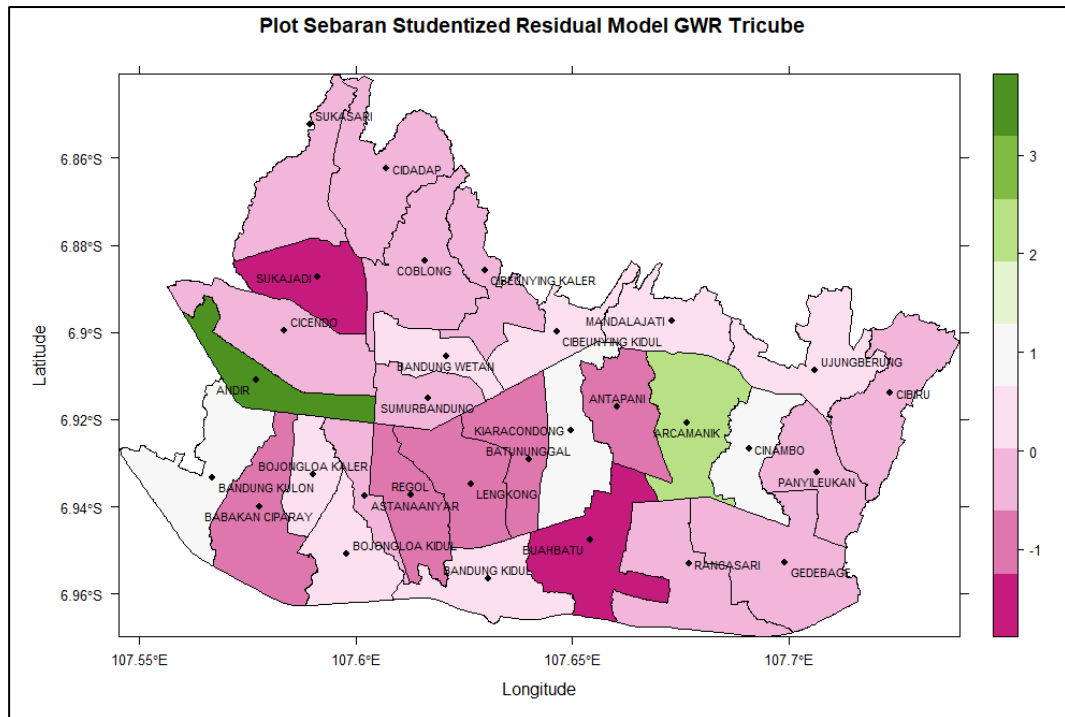
Pada peta di atas terlihat bahwa kecamatan di Kota Bandung dengan nilai mutlak dari *studentized* residual model GWR Bisquare terbesar adalah Andir, Arcamanik, Buahbatu, dan Sukajadi di mana range nilai mutlaknya antara lebih dari 1,5 sampai lebih dari 3 sehingga daerah-daerah tersebut dapat dikatakan terdeteksi sebagai *outlier*.

3.7.4. Residual dan *Studentized* Residual Model GWR Tricube

Akan dipetakan sebaran residual dan *studentized* residual model GWR Tricube dengan bantuan *software* RStudio.



Gambar 3.17 Peta Sebaran Nilai Residual Model GWR Tricube



Gambar 3.18 Peta Sebaran Nilai *Studentized* Residual Model GWR Tricube

Pada peta di atas terlihat bahwa kecamatan di Kota Bandung dengan nilai mutlak dari *studentized* residual model GWR Tricube terbesar adalah Andir, Arcamanik, Buahbatu, dan Sukajadi di mana range nilai mutlaknya antara lebih dari 1,5 sampai lebih dari 3 sehingga daerah-daerah tersebut dapat dikatakan terdeteksi sebagai *outlier*.

BAB IV

PENUTUP

4.1. Kesimpulan

1. Model *Geographically Weighted Regression* dengan fungsi pembobot spasial Kernel Gaussian pada pemodelan jumlah Bayi Berat Badan Lahir Rendah (BBLR) di Kota Bandung pada tahun 2019 memberikan hasil yang lebih baik ketika dibandingkan dengan model GWR dengan fungsi pembobot Kernel Bisquare dan Kernel Tricube karena menghasilkan skor R^2 yang lebih besar dan skor AIC yang lebih kecil.
2. Melalui model, didapat faktor-faktor yang mempengaruhi jumlah Bayi Berat Badan Lahir Rendah (BBLR) di Kota Bandung pada tahun 2019 secara signifikan adalah pemberian FE1 (Zat Besi) 30 tablet pada ibu hamil, jumlah rumah memenuhi syarat tidak sehat di Kota Bandung, dan jumlah populasi penduduk.
3. Berdasarkan keragaman spasial, nilai parameter yang positif dapat diinterpretasikan sebagai hubungan yang berbanding lurus antara jumlah Bayi Berat Badan Lahir Rendah (BBLR) dengan faktor-faktornya. Sedangkan, nilai parameter yang negatif dapat diinterpretasikan sebagai hubungan yang berbanding terbalik antara jumlah Bayi Berat Badan Lahir Rendah (BBLR) dengan faktor-faktornya.
4. Range nilai residual maupun *studentized* residual yang terbesar terdapat pada model regresi linear berganda dan yang terkecil adalah pada model GWR Gaussian. Dengan demikian patutlah bahwa model GWR Gaussian adalah model terbaik untuk menganalisis data jumlah bayi dengan Berat Badan Lahir Rendah (BBLR) di Kota Bandung pada tahun 2019.

4.2. Saran

1. Melalui penelitian ini, diharapkan pemerintah Kota Bandung dapat mempertimbangkan hasil penelitian ini untuk mengambil langkah yang tepat dalam rangka mengurangi jumlah kasus bayi dengan berat badan lahir rendah (BBLR) di Kota Bandung.
2. Dapat dilakukan penelitian lain menggunakan model GWR dengan faktor-faktor yang berbeda dari yang sudah ada dalam penelitian ini untuk memodelkan kasus bayi dengan berat badan lahir rendah (BBLR) di Kota Bandung atau di daerah yang berbeda dan di tahun yang berbeda juga.

DAFTAR PUSTAKA

- Badan Pusat Statistik Kota Bandung. 2022. Jumlah Bayi Lahir dan Bayi Berat Badan Lahir Rendah (BBLR) di Kota Bandung, 2017 dalam <https://bandungkota.bps.go.id/subject/30/kesehatan.html#subjekViewTab3>, (Diakses tanggal 5 November 2022)
- Fotheringham, A. S., Brunson, C., & Charlton, M. (2002). *Geographically weighted regression: the analysis of spatially varying relationships*. John Wiley & Sons.
- Maidartati, Sri, H., Hera, W. (2019). Faktor-Faktor yang Berhubungan dengan Kejadian Bayi Berat Lahir Rendah (BBLR) di RSUD Kota Bandung, 7(2): 323-328.
- <https://data.bandung.go.id/>
- <https://www.lapagis.com/p/shapefile.html>

LAMPIRAN

Data

row	Kecamatan	Latitude	Longitude	BBLR	FE1	FE2	K1	K4	PHBS	kms	RTS	pop	kpd
0	Gedebage	-6,95269	107,69916	3	676	639	675	595	6117	394	1815	40121	40
1	Ujungberung	-6,90875	107,70597	33	1430	1416	1505	1453	13685	1306	5087	86225	138
2	Cinambo	-6,92678	107,69083	34	436	427	465	455	2310	323	1499	25101	59
3	Bandung Kulon	-6,93338	107,56685	94	2347	2205	2486	2388	4857	2758	5744	132811	191
4	Andir	-6,91094	107,577	163	1832	1759	1729	1679	9906	1126	3357	99132	235
5	Babakan Ciparay	-6,94006	107,57766	23	2408	2354	2671	2429	4768	3338	12884	138788	196
6	Bojongloa Kaler	-6,93247	107,59003	30	2031	2000	2239	2099	15580	2503	6533	123467	396
7	Sukajadi	-6,88736	107,59122	28	1829	1800	1950	1801	10860	1148	3835	101315	192
8	Cidadap	-6,86242	107,60711	20	944	921	1009	979	4036	796	2572	53622	64
9	Coblong	-6,88364	107,61599	51	2013	2026	2344	2289	2092	874	7172	114163	156
10	Cicendo	-6,89966	107,5835	23	1686	1708	1584	1494	20066	843	9094	96008	123
11	Bandung Wetan	-6,90542	107,6209	2	458	460	345	349	3518	145	1030	28917	84
12	Sumur Bandung	-6,91502	107,61676	1	658	564	631	530	2546	351	2132	37061	106
13	Batununggal	-6,92921	107,63999	24	2105	2088	2482	2404	2944	1424	7538	120900	251
14	Cibeunying Kidul	-6,89973	107,64642	41	1906	1852	2077	1979	9167	869	3577	112903	273
15	Regol	-6,93731	107,61264	18	1461	1376	1328	1248	3994	699	4246	80141	169
16	Bandung Kidul	-6,95644	107,63053	29	1036	963	1028	949	8088	719	4477	59698	110
17	Astanaanyar	-6,9376	107,60207	26	1295	1287	1235	1198	1251	682	4096	74078	276
18	Kiaracondong	-6,92239	107,64974	52	2229	2218	2304	2289	9645	1618	12828	130075	224
19	Buahbatu	-6,94755	107,65426	2	1748	1772	1824	1778	9009	1256	2900	101022	135
20	Mandalajati	-6,89727	107,67291	11	1184	1097	1307	1252	2315	958	10273	70958	148
21	Cibiru	-6,91389	107,72351	16	1283	1275	1297	1158	9962	1256	3984	72791	106
22	Bojongloa Kidul	-6,95089	107,59793	37	1522	1521	1522	1490	8992	1599	8944	85639	165
23	Cibeunying Kaler	-6,88573	107,62974	9	1252	1234	635	631	9057	429	8473	69783	150
24	Panyileukan	-6,93213	107,70656	0	647	664	752	752	5000	259	821	39277	74
25	Antapani	-6,91715	107,66047	7	1351	1325	1342	1336	3550	559	2673	78564	186
26	Lengkong	-6,93485	107,62653	6	1283	1265	1206	1201	1536	628	3190	71295	121
27	Sukasari	-6,85236	107,58939	29	1321	1321	1392	1359	1565	373	2479	76942	121
28	Rancasari	-6,95311	107,677	22	1407	1270	1389	1253	2831	751	0	83428	119
29	Arcamanik	-6,92072	107,67648	91	1306	1277	1355	1271	1123	849	912	76239	100

Data estimasi parameter tiap fitur (Gaussian)

row	kecamatan	kelompok	Intercept	FE1	RTS	pop
0	Gedebage	0	1,5307328	0,095343789	-0,00125278	-0,0012611

1	Ujungberung	0	0,6060157	0,081040148	-0,001818655	-0,0009557
2	Cinambo	0	0,3707996	0,106189555	-0,00162776	-0,001404
3	Bandung Kulon	2	-17,558848	0,35589773	-0,004804326	-0,0053308
4	Andir	1	-15,39652	0,333937892	-0,004355718	-0,0050006
5	Babakan Ciparay	1	-15,794621	0,333196339	-0,004234152	-0,0049939
6	Bojongloa Kaler	1	-14,190305	0,316602032	-0,003920304	-0,0047423
7	Sukajadi	1	-13,770166	0,315683663	-0,004096547	-0,0047164
8	Cidadap	0	-11,484439	0,281813406	-0,003703763	-0,0041758
9	Coblong	0	-10,324847	0,266880749	-0,00339576	-0,0039487
10	Cicendo	1	-14,786959	0,327655667	-0,0042619	-0,0049036
11	Bandung Wetan	0	-9,9138953	0,263872419	-0,003221681	-0,003914
12	Sumur Bandung	0	-10,168016	0,268341156	-0,003209928	-0,0039911
13	Batununggal	0	-6,4117336	0,22091176	-0,002516252	-0,0032554
14	Cibeunying Kidul	0	-5,7495978	0,203227793	-0,002580413	-0,0029468
15	Regol	0	-10,272865	0,27151955	-0,00306992	-0,0040583
16	Bandung Kidul	0	-6,4886802	0,228908453	-0,002304258	-0,0034139
17	Astanaanyar	1	-12,237215	0,294147455	-0,003492693	-0,0044014
18	Kiaracandong	0	-4,4429677	0,192529168	-0,002238618	-0,0028027
19	Buahbatu	0	-2,8009859	0,177437116	-0,00181885	-0,0025927
20	Mandalajati	0	-2,3963199	0,144979121	-0,002179041	-0,0019998
21	Cibiru	0	1,5081843	0,054965817	-0,001652615	-0,0005316
22	Bojongloa Kidul	1	-12,620238	0,29792171	-0,003458255	-0,0044677
23	Cibeunying Kaler	0	-8,1808621	0,235890795	-0,003011218	-0,0034579
24	Panyileukan	0	1,3990009	0,08083118	-0,001474779	-0,0009903
25	Antapani	0	-2,9797053	0,166441859	-0,002097117	-0,0023746
26	Lengkong	0	-8,3015828	0,247151242	-0,002764927	-0,0036755
27	Sukasari	1	-13,809394	0,318268187	-0,004210656	-0,0047541
28	Rancasari	0	-0,1106816	0,135534209	-0,00141006	-0,0019265
29	Arcamanik	0	-1,1106025	0,1335512	-0,001858652	-0,0018426

Output RStudio

Matriks Jarak antar Lokasi Pengamatan

```
      [,1]      [,2]      [,3]      [,30]
[1,] 0.00000000 0.04752816 0.02517974 0.13374427
[2,] 0.04752816 0.00000000 0.02618307 0.14318019
[3,] 0.02517974 0.02618307 0.00000000 0.12685308
[4,] 0.13374427 0.14318019 0.12685308 0.00000000
[5,] 0.12412098 0.12587786 0.11297495 0.02540132
[6,] 0.11852746 0.13279286 0.11418935 0.01898000
[7,] 0.10925209 0.11953061 0.10241262 0.02459894
[8,] 0.12449666 0.11691980 0.10891007 0.04968081
[9,] 0.12691425 0.10812058 0.10687041 0.07907502
[10,] 0.10575970 0.09279438 0.08747674 0.06823150
      ⋮          ⋮          ⋮          ⋮
[29,] 0.02238409 0.05950931 0.03333916 0.11296178
[30,] 0.03745013 0.03156541 0.01584335 0.11340262
```

Estimasi Parameter Model GWR (Kernel Gaussian)

```
*****
*           Results of Geographically Weighted Regression           *
*****

*****Model calibration information*****
Kernel function: gaussian
Fixed bandwidth: 0.1587755
Regression points: the same locations as observations are used.
Distance metric: Euclidean distance metric is used.

*****Summary of GWR coefficient estimates:*****
      Min.      1st Qu.      Median      3rd Qu.      Max.
Intercept -9.6186164 -7.6095715 -6.2156746 -5.3831418 -4.3980
FE1        0.2312274  0.2437423  0.2499985  0.2603509  0.2728
RTS        -0.0032173 -0.0030987 -0.0029941 -0.0029260 -0.0028
pop        -0.0040683 -0.0038770 -0.0037239 -0.0036247 -0.0034
*****Diagnostic information*****
Number of data points: 30
Effective number of parameters (2trace(S) - trace(S'S)): 4.620959
Effective degrees of freedom (n-2trace(S) + trace(S'S)): 25.37904
```

AICc (GWR book, Fotheringham, et al. 2002, p. 61, eq 2.33): 295.2218
 AIC (GWR book, Fotheringham, et al. 2002, GWR p. 96, eq. 4.22): 286.0594
 BIC (GWR book, Fotheringham, et al. 2002, GWR p. 61, eq. 2.34): 266.4356
 Residual sum of squares: 21048.61
 R-square value: 0.3661998
 Adjusted R-square value: 0.2460652

Estimasi Parameter Model GWR (Kernel Bisquare)

 * Results of Geographically Weighted Regression *

*****Model calibration information*****

Kernel function: bisquare
 Fixed bandwidth: 0.1587755
 Regression points: the same locations as observations are used.
 Distance metric: Euclidean distance metric is used.

*****Summary of GWR coefficient estimates:*****

	Min.	1st Qu.	Median	3rd Qu.	Max.
Intercept	-30.3640462	-11.0737509	-4.8420162	-1.7670548	1.0165
FE1	0.1169030	0.1754250	0.2113797	0.2590960	0.3258
RTS	-0.0042414	-0.0031930	-0.0027121	-0.0023833	-0.0015
pop	-0.0047423	-0.0038034	-0.0030872	-0.0025476	-0.0016

*****Diagnostic information*****

Number of data points: 30
 Effective number of parameters ($2\text{trace}(S) - \text{trace}(S'S)$): 6.660331
 Effective degrees of freedom ($n - 2\text{trace}(S) + \text{trace}(S'S)$): 23.33967
 AICc (GWR book, Fotheringham, et al. 2002, p. 61, eq 2.33): 295.4312
 AIC (GWR book, Fotheringham, et al. 2002, GWR p. 96, eq. 4.22): 283.4527
 BIC (GWR book, Fotheringham, et al. 2002, GWR p. 61, eq. 2.34): 266.8018
 Residual sum of squares: 18516.81
 R-square value: 0.4424356
 Adjusted R-square value: 0.2762039

Estimasi Parameter Model GWR (Kernel Tricube)

```
*****
*               Results of Geographically Weighted Regression               *
*****

*****Model calibration information*****
Kernel function: tricube
Fixed bandwidth: 0.1587755
Regression points: the same locations as observations are used.
Distance metric: Euclidean distance metric is used.

*****Summary of GWR coefficient estimates:*****
              Min.      1st Qu.      Median      3rd Qu.      Max.
Intercept -31.2058961 -10.2616711  -4.9383944  -2.3296084   0.4430
FE1         0.1052849   0.1672200   0.2234908   0.2624828   0.3260
RTS         -0.0042827  -0.0031557  -0.0028362  -0.0022903  -0.0014
pop         -0.0046553  -0.0038754  -0.0032854  -0.0023847  -0.0014
*****Diagnostic information*****
Number of data points: 30
Effective number of parameters (2trace(S) - trace(S'S)): 5.851329
Effective degrees of freedom (n-2trace(S) + trace(S'S)): 24.14867
AICc (GWR book, Fotheringham, et al. 2002, p. 61, eq 2.33): 295.6539
AIC (GWR book, Fotheringham, et al. 2002, GWR p. 96, eq. 4.22): 284.7379
BIC (GWR book, Fotheringham, et al. 2002, GWR p. 61, eq. 2.34): 267.0186
Residual sum of squares: 19616.08
R-square value: 0.4093352
Adjusted R-square value: 0.2600318

*****
```

Output sebaran peubah signifikan

```
> gwr.t.adjust(gwr.gaus)[["results"]][["p"]]
      Intercept_p    FE1_p RTS_p pop_p
0          0.933    0.515 0.591 0.619
1          0.973    0.602 0.445 0.722
2          0.983    0.456 0.478 0.569
3          0.367    0.027 0.072 0.049
4          0.408    0.031 0.080 0.055
5          0.399    0.033 0.093 0.058
6          0.432    0.036 0.101 0.063
7          0.455    0.036 0.091 0.064
8          0.534    0.055 0.124 0.093
9          0.553    0.060 0.137 0.102
10         0.425    0.032 0.083 0.057
11         0.558    0.061 0.147 0.101
12         0.547    0.058 0.147 0.096
13         0.692    0.102 0.242 0.159
```


14	0.724	0.130	0.240	0.200
15	0.543	0.057	0.166	0.094
16	0.691	0.098	0.288	0.148
17	0.482	0.045	0.126	0.076
18	0.783	0.148	0.300	0.220
19	0.863	0.185	0.402	0.260
20	0.885	0.286	0.336	0.393
21	0.938	0.755	0.499	0.862
22	0.474	0.045	0.137	0.076
23	0.626	0.087	0.178	0.141
24	0.940	0.600	0.532	0.711
25	0.855	0.211	0.339	0.299
26	0.614	0.075	0.202	0.120
27	0.472	0.038	0.095	0.066
28	0.995	0.321	0.529	0.413
29	0.947	0.327	0.408	0.432

Input R Code

```
library(GWmodel)
library(maptools)
library(RColorBrewer)
library(shapefiles)
library(readxl)
install.packages('carData')
install.packages('sp')
library(carData)
install.packages('nortest')
library(nortest)
install.packages('lmtest')
library(lmtest)
library(sp)
library(rgdal) # membaca shapefile
install.packages("spData")
library(spData)
library(raster) # text pada peta
install.packages("spdep")
library(spdep) # pembobot data spasial
install.packages('sf')
install.packages('DescTools')
library(DescTools) # Uji dependensi
install.packages("spatialreg")
```

```

library(spatialreg) # running model SAR
install.packages("GWmodel")
library(GWmodel) # Model GWR
install.packages('olsrr')
library('olsrr')

#input data
datagwr<-read_excel("Downloads/data2019.xlsx")
View(datagwr)
FE1 <- datagwr$X_1
FE2 <- datagwr$X_2
K1 <- datagwr$X_3
K4 <- datagwr$X_4
PBHS <- datagwr$X_5
kms <- datagwr$X_6
RTS <- datagwr$X_7
pop <- datagwr$X_8
kpd <- datagwr$X_9
BBLR <- datagwr$Y

#mencari model terbaik
library(MASS)
# Fit the full model
full.model <- lm(BBLR ~ FE1+ FE2+K1+K4+PBHS+kms+RTS+pop+kpd, data =
datagwr)
summary(full.model)
ols_step_forward_p(full.model)
plot(k)

model <- lm(y~FE1+pop+RTS,data=datagwr)
AIC(model)
summary(model)

#Uji Asumsi Multiko
install.packages('car')
library(car)
vif(model)
vif(mod1)
#tidak terjadi multiko pada RTS, ada multiko pada FE1 dan pop
#Uji Asumsi Normalitas

```

```

#H0: error normal
ad.test(model$residuals)
ad.test(mod1$residuals)
#Nilai pvalue = 0,1086 > alpha = 0,05, sehingga H0 tidak ditolak
#Uji Asumsi Autokorelasi
#H0: tidak terdapat korelasi
durbinWatsonTest(model)
durbinWatsonTest(mod1)
#Nilai pvalue = 1,964 > alpha = 0,05, sehingga H0 tidak ditolak
#tidak ada autokorelasi
#Uji Asumsi Heteroskedastisitas
#H0: tidak terjadi hetero
bptest(model)
bptest(mod1)
#Nilai pvalue = 0,01664 < alpha = 0,05, sehingga H0 ditolak
#data hetero

#buka shp bandung
x<-readShapeSpatial("D:/coolyeah/smt 7/spasial/1.
MINE/b_kecamatan_polygon_327320190709113339/b_kecamatan_polygon_32732019070
9113339.shp")
coordinates(x)

#GWR
# Mendapatkan matriks jarak antar lokasi observasi.
head(data)
data.spdf<-SpatialPointsDataFrame(coordinates(x),data)
head(data.spdf)
m.jarak<-gw.dist(dp.locat=coordinates(data.spdf))
m.jarak
head(m.jarak)

#Metode Pseudo-stepwise
#Untuk model GWR dengan fungsi Kernel Gaussian
DeVar<-"BBLR"
InDeVars<-c("FE1", "RTS", "pop")
model.sel<-model.selection.gwr(DeVar, InDeVars, data=data.spdf,
kernel="gaussian", adaptive=FALSE, bw=1, approach="CV", dMat=m.jarak)
sorted.models<-model.sort.gwr(model.sel,numVars=length(InDeVars),
ruler.vector=model.sel[[2]][,2])
model.list<-sorted.models[[1]]

```

```

model.view.gwr(DeVar, InDeVars, model.list=model.list)
plot(sorted.models[[2]][,2],col="black", pch=20, lty=5, main = "Alternative
view of GWR model selection procedure", ylab = "CV", xlab = "Model number",
type = "b")

```

#Untuk model GWR dengan fungsi Kernel Bisquare

```

DeVar<-"BBLR"
InDeVars<-c("FE1", "RTS", "pop")
model.sel<-model.selection.gwr(DeVar, InDeVars, data=data.spdf,
kernel="bisquare", adaptive=FALSE, bw=1, approach="CV", dMat=m.jarak)
sorted.models<-model.sort.gwr(model.sel,numVars=length(InDeVars),
ruler.vector=model.sel[[2]][,2])
model.list<-sorted.models[[1]]
model.view.gwr(DeVar, InDeVars, model.list=model.list)
plot(sorted.models[[2]][,2],col="black", pch=20, lty=5, main = "Alternative
view of GWR model selection procedure", ylab = "CV", xlab = "Model number",
type = "b")

```

#Untuk model GWR dengan fungsi Kernel Tricube

```

DeVar<-"BBLR"
InDeVars<-c("FE1", "RTS", "pop")
model.sel<-model.selection.gwr(DeVar, InDeVars, data=data.spdf,
kernel="tricube", adaptive=FALSE, bw=1, approach="CV", dMat=m.jarak)
sorted.models<-model.sort.gwr(model.sel,numVars=length(InDeVars),
ruler.vector=model.sel[[2]][,2])
model.list<-sorted.models[[1]]
model.view.gwr(DeVar, InDeVars, model.list=model.list)
plot(sorted.models[[2]][,2],col="black", pch=20, lty=5, main = "Alternative
view of GWR model selection procedure", ylab = "CV", xlab = "Model number",
type = "b")

```

#Menentukan bandwidth optimum

Mendapatkan matriks jarak antar lokasi observasi.

```

data.spdf<-SpatialPointsDataFrame(coordinates(x),data)
data.spdf

```

#Untuk model GWR dengan fungsi Kernel Gaussian

```

bw.mod.gwr.gauss<-bw.gwr(BBLR~FE1+RTS+pop, data=data.spdf, approach="CV",
kernel="gaussian", adaptive=F)
bw.mod.gwr.gauss

```

```

gwr.gaus<-gwr.basic(BBLR~FE1+RTS+pop, data = data.spdf,
bw=bw.mod.gwr.gauss, kernel="gaussian", adaptive=F)
print(gwr.gaus)

#Untuk model GWR dengan fungsi Kernel bisquare
bw.mod.gwr.bisq<-bw.gwr(BBLR~FE1+RTS+pop, data=data.spdf, approach="CV",
kernel="bisquare", adaptive=F)
bw.mod.gwr.bisq

gwr.bisq<-gwr.basic(BBLR~FE1+RTS+pop, data = data.spdf, bw=bw.mod.gwr.bisq,
kernel="bisquare", adaptive=F)
print(gwr.bisq)

#Untuk model GWR dengan fungsi Kernel tricube
bw.mod.gwr.tric<-bw.gwr(BBLR~FE1+RTS+pop, data=data.spdf, approach="CV",
kernel="tricube", adaptive=F)
bw.mod.gwr.tric

gwr.tric<-gwr.basic(BBLR~FE1+RTS+pop, data = data.spdf, bw=bw.mod.gwr.tric,
kernel="tricube", adaptive=F)
print(gwr.tric)


library(readxl)
library(MASS)
library(lmtest)
library(openxlsx)
library(GWmodel)
library(maptools)
library(RColorBrewer)
library(sp)
library(foreign)
library(lattice)
library(rgdal)
library(classInt)
library(class)
library(e1071)
library(shapefiles)
library(tmap)

```

```

# import dataset
df <- read_excel("tugas3.xlsx", sheet="data")
koord <- read_excel("tugas3.xlsx", sheet="koord")
shp <-
readOGR("C:/Users/Alfia/Downloads/b_kecamatan_polygon_bandung/b_kecamatan_p
olygon_327320190709113339.shp")

## Menentukan bandwidth optimum ##
# Mendapatkan matriks jarak antar lokasi observasi.
data.spdf<-SpatialPointsDataFrame(coordinates(shp),df)
data.spdf@data

## Untuk model GWR dengan fungsi Kernel Gaussian ##
bw.mod.gwr.gauss <- bw.gwr(BBLR~FE1+RTS+pop, data=data.spdf, approach="CV",
kernel="gaussian", adaptive=F)
gwr.gaus <- gwr.basic(BBLR~FE1+RTS+pop, data = data.spdf,
bw=bw.mod.gwr.gauss, kernel="gaussian", adaptive=F)
print(gwr.gaus)
View(gwr.gaus$SDF)
#Melakukan uji signifikansi parameter GWR
gwr.t.adjust(gwr.gaus)
#signifikansi tiap fitur
gwr.t.adjust(gwr.gaus)[["results"]][["p"]]
gwr.t.adjust(gwr.gaus)$results$bh
#estimasi parameter
gwr.gaus$SDF@data

## Untuk model GWR dengan fungsi Kernel Bisquare ##
bw.mod.gwr.bisq <- bw.gwr(BBLR~FE1+RTS+pop, data=data.spdf, approach="CV",
kernel="bisquare", adaptive=F)
gwr.bisq <- gwr.basic(BBLR~FE1+RTS+pop, data = data.spdf,
bw=bw.mod.gwr.bisq, kernel="bisquare", adaptive=F)
print(gwr.bisq)
#Melakukan uji signifikansi parameter GWR
gwr.t.adjust(gwr.bisq)
#signifikansi tiap fitur
gwr.t.adjust(gwr.bisq)[["results"]][["p"]]
gwr.t.adjust(gwr.bisq)$results$bh
#estimasi parameter
gwr.bisq$SDF@data

```

```

## Untuk model GWR dengan fungsi Kernel Tricube ##
bw.mod.gwr.tric <- bw.gwr(BBLR~FEI+RTS+pop, data=data.spdf, approach="CV",
kernel="tricube", adaptive=F)
gwr.tric <- gwr.basic(BBLR~FEI+RTS+pop, data = data.spdf,
bw=bw.mod.gwr.tric, kernel="tricube", adaptive=F)
print(gwr.tric)
#Melakukan uji signifikansi parameter GWR
gwr.t.adjust(gwr.tric)
#signifikansi tiap fitur
gwr.t.adjust(gwr.tric)[["results"]][["p"]]
gwr.t.adjust(gwr.tric)$results$bh
#estimasi parameter
gwr.tric$SDF@data

#Plot Fitur Signifikan FIX
shp <-
readOGR("C:/Users/Alfia/Downloads/b_kecamatan_polygon_bandung/b_kecamatan_p
olygon_327320190709113339.shp")
beta <- read_excel("tugas3.xlsx", sheet="beta")
shp@data$row <- as.numeric(row.names(shp@data))
beta$kecamatan <- as.factor(beta$kecamatan)
shp@data$row <- as.numeric(row.names(shp@data))
shp@data$no <- as.numeric(row.names(shp@data))
temp <- merge(shp@data, beta, by="row", all.x=T, sort=F)
shp@data <- temp[order(temp$row),]
plotvar <- shp@data$kelompok
nclr <- 9
plotclr <- brewer.pal(nclr,"Blues")
plotclr <- plotclr[1:nclr]
class <- classIntervals(plotvar, nclr, style="equal")
colcode <- findColours(class, plotclr, digits=4)
plot(shp, density=16, col="grey", axes=F, cex.axis=.75)
plot(shp, col=colcode, add=T)
text(coordinates(shp), labels=shp$nama, cex=.5)

# import shp Bandung
shp <-
readOGR("C:/Users/Alfia/Downloads/b_kecamatan_polygon_bandung/b_kecamatan_p
olygon_327320190709113339.shp")
shp@data$row <- as.numeric(row.names(shp@data))
temp <- merge(shp@data,beta,by="row",all.xx=T,sort=F)

```

```

shp@data <- temp[order(temp$row),]
koord.spdf <- SpatialPointsDataFrame(koord[,3:1],koord)
kec <-
list('sp.pointLabel',koord.spdf,label=shp@data$nama[1:30],cex=0.7,col='black')
titik <- list('sp.points',koord.spdf,pch=19,cex=.8,col='black')

### Plot Estimasi Parameter X ###
# Beta_1
spplot(shp,'FE1',col.regions=brewer.pal(9,"Oranges"),main="Peta Sebaran
Nilai Penduga Parameter
Beta_1",scales=list(draw=TRUE),sp.layout=list(kec,titik),xlab='Longitude',y
lab='Latitude',cuts=8)
# Beta_7
spplot(shp,'RTS',col.regions=brewer.pal(9,"Greens"),main="Peta Sebaran
Nilai Penduga Parameter
Beta_7",scales=list(draw=TRUE),sp.layout=list(kec,titik),xlab='Longitude',y
lab='Latitude',cuts=8)
# Beta_8
spplot(xx,'pop',col.regions=brewer.pal(9,"Purples"),main="Peta Sebaran
Nilai Penduga Parameter
Beta_8",scales=list(draw=TRUE),sp.layout=list(kec,titik),xlab='Longitude',y
lab='Latitude',cuts=8)

### PLOT RESIDUAL ###
res <- read_excel("tugas3.xlsx", sheet="res")
shp@data$row <- as.numeric(row.names(shp@data))
temp <- merge(shp@data,res,by="row",all.xx=T,sort=F)
shp@data <- temp[order(temp$row),]

koord.spdf<-SpatialPointsDataFrame(koord[,3:1],koord)
kec <-
list('sp.pointLabel',koord.spdf,label=shp@data$nama[1:30],cex=0.7,col='black')
titik<-list('sp.points',koord.spdf,pch=19,cex=.8,col='black')

# Residual Regresi Linier
spplot(shp,'res.reg',col.regions=brewer.pal(9,"PiYG"),

```



```

    main="Plot Sebaran Residual Regresi Linier",
    scales=list(draw=TRUE), sp.layout=list(kec, titik), xlab='Longitude', ylab='Latitude', cuts=8)

# Residual GWR Gaussian
spplot(shp, 'res.gaus', col.regions=brewer.pal(9, "PiYG"),
    main="Plot Sebaran Residual Model GWR Gaussian",
    scales=list(draw=TRUE), sp.layout=list(kec, titik), xlab='Longitude', ylab='Latitude', cuts=8)

# Residual GWR Bisquare
spplot(shp, 'res.bisq', col.regions=brewer.pal(9, "PiYG"),
    main="Plot Sebaran Residual Model GWR Bisquare",
    scales=list(draw=TRUE), sp.layout=list(kec, titik), xlab='Longitude', ylab='Latitude', cuts=8)

# Residual GWR Tricube
spplot(shp, 'res.tric', col.regions=brewer.pal(9, "PiYG"),
    main="Plot Sebaran Residual Model GWR Tricube",
    scales=list(draw=TRUE), sp.layout=list(kec, titik), xlab='Longitude', ylab='Latitude', cuts=8)

### Plot Studentized Residual ###
stud.res <- read_excel("tugas3.xlsx", sheet="stud.res")
temp <- merge(shp@data, stud.res, by="row", all.x=T, sort=F)
shp@data <- temp[order(temp$row),]

koord.spdf<-SpatialPointsDataFrame(koord[,3:1], koord)
kec <-
list('sp.pointLabel', koord.spdf, label=shp@data$nama[1:30], cex=0.7, col='black')
titik<-list('sp.points', koord.spdf, pch=19, cex=.8, col='black')

# Studentized Residual Regresi Linier
spplot(shp, 'stud.res.reg', col.regions=brewer.pal(9, "PiYG"),
    main="Plot Sebaran Studentized Residual Regresi Linier",
    scales=list(draw=TRUE), sp.layout=list(kec, titik), xlab='Longitude', ylab='Latitude', cuts=8)

# Studentized Residual GWR Gaussian
spplot(shp, 'stud.res.gaus', col.regions=brewer.pal(9, "PiYG"),

```

```

    main="Plot Sebaran Studentized Residual Model GWR Gaussian",
    scales=list(draw=TRUE),sp.layout=list(kec,titik),xlab='Longitude',yl
    ab='Latitude',cuts=8)

# Studentized Residual GWR Bisquare
spplot(shp,'stud.res.bisq',col.regions=brewer.pal(9,"PiYG"),
    main="Plot Sebaran Studentized Residual Model GWR Bisquare",
    scales=list(draw=TRUE),sp.layout=list(kec,titik),xlab='Longitude',yl
    ab='Latitude',cuts=8)

# Studentized Residual GWR Tricube
spplot(shp,'stud.res.tric',col.regions=brewer.pal(9,"PiYG"),
    main="Plot Sebaran Studentized Residual Model GWR Tricube",
    scales=list(draw=TRUE),sp.layout=list(kec,titik),xlab='Longitude',yl
    ab='Latitude',cuts=8)

```